

Inhaltsverzeichnis

1	Stochastische Modelle in der Robotik	1
1.1	Geschwindigkeitsbasiertes Bewegungsmodell	3
2	Kartenerstellung	7
2.1	Occupancy-Grid-Mapping	7
3	ROS-Navigation-Stack	11
3.1	Funktionsprinzip des globalen Planers	12
3.2	Optimale Suche und Planung	15
3.2.1	A*	15
	Literaturverzeichnis	17

Kapitel 1

Stochastische Modelle in der Robotik

Jede elabourierte Methoden erfordert einen Rahmen, in dem sie erarbeitet, formuliert und optimiert werden kann. In technischen Aufgabenstellung erfüllt die Mathematik diese Forderung, weshalb die Gegebenheiten und Probleme des hiesigen Anwendungsfall zunächst in einem mathematischen Kontext dargestellt werden. Denn nur von dieser Basis ausgehend, besteht die Aussicht auf eine elegante und ansprechende Lösung.

Wie alle Probleme der Robotik, kann auch die autonome Navigation im entferntesten Sinne als Interaktion eines Roboters mit seiner Umwelt aufgefasst werden. Anhand von gesammelten Informationen muss das System eine Entscheidung über seine zukünftigen Aktionen treffen, wobei ein entferntes Ziel ohne ungewollte Kollisionen angesteuert werden soll. Für diese Aufgaben spielen drei Größen eine fundamentale Rolle. Zunächst muss die Position des Roboters beachtet werden, welche in dem Positionsvektor $\vec{x}(t) \equiv \vec{x}_t$ erfasst wird. Mithilfe von Sensoren sammelt der Roboter Informationen über seine Umgebung, die in dem Messvektor \vec{z}_t zusammengefasst werden. Anhand der Mess- und Positionsvektoren wird über die nächste Aktion des Roboters entschieden, die in dem Steuervektor \vec{u}_t ausgedrückt wird. Die exakte Form der Positions-, Mess- und Steuervektoren hängt von dem gegebenen Anwendungsfall und gewählten Modellformen ab, die im Folgenden näher erläutert werden.

In anderen Fachgebieten, die sich mit der Planung von Steuersignalen bzw. -sequenzen beschäftigen - wie z.B. die Regelungstechnik -, haben sich modellbasierte Methoden bewährt. Zunächst wird auf Basis von physikalischen Gegebenheiten der Zusammenhang zwischen Steuer-, Zustands- und Messvektor hergeleitet, der anschließend genutzt wird, um eine Regelstrategie zu formulieren. Der resultierende Algorithmus berechnet die Stellgröße \vec{u}_t , wofür die aktuellen Mess- und Zustandsvektoren herangezogen werden. Insofern liegt es nahe modellbasierte Ansätze auch bei Problemen der Robotik zu verfolgen. Allerdings kommt dort die ungemeine Komplexität der Problemstellung zu tragen, die sich recht leicht am Beispiel der Navigation illustrieren lässt: Als erstes muss ein Modell für den Einfluss des Stellvektors \vec{u}_t auf den Positionsvektor \vec{x}_t erstellt werden. Bei mobilen Roboterplattformen handelt es sich um mechanische Systeme mit mehreren Freiheitsgraden, womit die analytische Modellbildung zwar möglich, jedoch mit einem beachtlichen Aufwand verbunden ist. Spätestens bei der Modellierung der Sensoren werden die Grenzen des Möglichen erreicht: Soll beispielsweise die Position des Roboters mithilfe von Stereokameras erfasst werden kann praktisch kaum ein exaktes, deterministisches Modell für diesen Vorgang erfasst werden, da er von zu vielen unbekannten Einflussfaktoren betroffen ist. Zuletzt kann die Pfadplanung per Definition nicht anhand eines deterministischen Modells erfolgen, da der Roboter dynamischen Hindernissen ausweichen soll, deren Form, Bewegung in der Aufgabenstellung nicht näher spezifiziert werden.

Aus diesen Gründen haben sich in der Robotik stochastische Modellformen etabliert, wobei recht simple Ausgangsmodelle verwendet werden, die um Zufallsvariablen ergänzt werden, um die Ungenauigkeiten und Ungewissheiten des Modells zu repräsentieren. Das Ziel besteht nicht mehr darin konkrete Aussagen über den Verlauf von Zustandsgrößen zu treffen, wie dies z.B. bei einer Zustandsraumdarstellung der Form

$$\vec{x}(n+1) = \underline{\mathbf{A}} \cdot \vec{x}(n) + \underline{\mathbf{B}} \cdot \vec{u}(n) \quad (1.1)$$

erfolgt. Vielmehr soll mithilfe des Modells eine bedingte Wahrscheinlichkeit

$$p(\vec{x}(n+1) \mid \vec{x}(n), \vec{u}(n)) \quad (1.2)$$

berechnet werden. Im Anschluss können die Methoden der Wahrscheinlichkeitstheorie genutzt werden, um Filter- und Planungsalgorithmen zu entwerfen. Um einen ersten Eindruck für die-

se Modellformen zu erhalten, werden im Anschluss rudimentäre Ansätze für ein Bewegungs- und Sensormodell vorgestellt.

1.1 Geschwindigkeitsbasiertes Bewegungsmodell

¹ Als erstes Beispiel wird ein stochastisches Modell für die Roboterbewegung entworfen, wobei anhand des vergangenen Positionsvektor \vec{x}_{t-1} und des aktuellen Steuervektors \vec{u}_t die Wahrscheinlichkeitsverteilung des aktuellen Positionsvektors \vec{x}_t

$$p(\vec{x}_t \mid \vec{u}_t, \vec{x}_{t-1}) \quad (1.3)$$

bestimmt werden soll. In diesem Fall wird lediglich eine planare Bewegung betrachtet, das heißt der Roboter bewegt sich in der xy-Ebene. Der Positionsvektor setzt sich somit aus den drei Größen

$$\vec{x} = \begin{pmatrix} x \\ y \\ \theta \end{pmatrix} \quad (1.4)$$

zusammen, welche die x-/y-Position und Ausrichtung des Roboters wiedergeben. θ gibt dabei den Winkel zwischen der x-Koordinatenachse und der Blickrichtung des Roboters an. Der Steuervektor \vec{u} gibt die aktuelle Translations- und Rotationsgeschwindigkeit

$$\vec{u} = \begin{pmatrix} v \\ \omega \end{pmatrix} \quad (1.5)$$

des Roboters an, wobei angenommen wird, dass die beiden Geschwindigkeiten zwischen zwei Abtastpunkten t und $t+1$ konstant sind. v beschreibt die Translationsgeschwindigkeit in Blickrichtung, während ω die Änderung des Blickwinkels θ wiedergibt. Unter der Annahme dass die Geschwindigkeiten \vec{u} in dem Intervall $[t-1, t]$ zwischen zwei Abtastpunkten konstant bleibt, kann die Bewegung als Rotation um einen konstanten Momentanpol $\vec{c} = (x_c \ y_c)^T$ betrachtet werden.




Abbildung 1.1: Darstellung des Momentanpols am Zeitpunkt t [1, S. 126]

Für den Radius gilt

$$r = \left| \frac{v}{\omega} \right|, \quad (1.6)$$

¹Das Bewegungsmodell und dessen Herleitung stammen aus [1, S. 121 ff]

wobei zu beachten ist, dass der Radius für eine Winkelgeschwindigkeit $\omega = 0$ gegen unendlich konvergiert, was wiederum einer reinen Translation entspricht. Aus dem Positionsvektors des Roboters \vec{x}_t an dem Zeitpunkt t kann der Momentanpol für die folgende Abtastperiode berechnet werden:

$$\begin{pmatrix} x_c \\ y_c \end{pmatrix} = \begin{pmatrix} x(t) - \frac{v}{\omega} \cdot \sin[\theta] \\ y(t) + \frac{v}{\omega} \cdot \cos[\theta] \end{pmatrix} \quad \leftrightarrow \quad \begin{pmatrix} x(t) \\ y(t) \end{pmatrix} = \begin{pmatrix} x_c + \frac{v}{\omega} \cdot \sin[\theta] \\ y_c - \frac{v}{\omega} \cdot \cos[\theta] \end{pmatrix}. \quad (1.7)$$

Im nächsten Schritt wird die Bewegung über eine Abtastperiode Δt betrachtet, wodurch der Roboter um die Winkeldifferenz $\Delta t \cdot \omega$ auf dem Kreisbogen wandert. Nach 1.7 folgt für den Positionsvektor am Zeitpunkt $t + \Delta t$

$$\begin{aligned} \begin{pmatrix} x(t + \Delta t) \\ y(t + \Delta t) \\ \theta(t + \Delta t) \end{pmatrix} &= \begin{pmatrix} x_c + \frac{v}{\omega} \cdot \sin[\theta(t) + \omega \cdot \Delta t] \\ y_c - \frac{v}{\omega} \cdot \cos[\theta(t) + \omega \cdot \Delta t] \\ \theta(t) + \omega \cdot \Delta t \end{pmatrix} \\ &= \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix} + \begin{pmatrix} -\frac{v}{\omega} \cdot \sin[\theta(t)] + \frac{v}{\omega} \cdot \sin[\theta(t) + \omega \cdot \Delta t] \\ \frac{v}{\omega} \cdot \cos[\theta(t)] - \frac{v}{\omega} \cdot \cos[\theta(t) + \omega \cdot \Delta t] \\ \omega \cdot \Delta t \end{pmatrix}. \end{aligned} \quad (1.8)$$

Bisher wurden lediglich deterministische Bewegungen betrachtet. Um nun mögliche Fehler des Steuervektors \vec{u} zu beachten, werden die störbehafteten Geschwindigkeiten

$$\vec{u} = \begin{pmatrix} \hat{v} \\ \hat{\omega} \end{pmatrix} = \begin{pmatrix} v + v_{\text{err}} \\ \omega + \omega_{\text{err}} \end{pmatrix} \quad (1.9)$$

eingeführt. Die Zufallsvariablen v_{err} und ω_{err} dienen der Fehlermodellierung und ihre Wahrscheinlichkeitsverteilungen ε_v und ε_ω werden dem Anwendungsfall nach angepasst. Einsetzen des stochastischen Steuervektors \vec{u} liefert

$$\begin{pmatrix} x(t + \Delta t) \\ y(t + \Delta t) \\ \theta(t + \Delta t) \end{pmatrix} = \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix} + \begin{pmatrix} -\frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t)] + \frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t)] - \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \hat{\omega} \cdot \Delta t \end{pmatrix}. \quad (1.10)$$

In diesem Modell wurden lediglich zwei Zufallsvariablen eingeführt, um die Störung von drei Positionsvariablen zu modellieren. Aus diesem Grund entsteht eine ungewollte stochastische Abhängigkeit zwischen den Elementen des Positionsvektors $\vec{x}(t + \Delta t)$. Dieses Problem wird behoben, indem eine dritte Zufallsvariable

$$\gamma_{\text{err}} \equiv \hat{\gamma} \quad (1.11)$$

eingeführt wird, die zu einer zusätzlichen Störung der Orientierung $\theta(t + \Delta t)$ in Form von

$$\begin{pmatrix} x(t + \Delta t) \\ y(t + \Delta t) \\ \theta(t + \Delta t) \end{pmatrix} = \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix} + \begin{pmatrix} -\frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t)] + \frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t)] - \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \hat{\omega} \cdot \Delta t + \hat{\gamma} \cdot \Delta t \end{pmatrix} \quad (1.12)$$

führt. Die Aufgabe besteht jetzt darin, ein Bewegungsmodell in Form der bedingten Wahr-

scheinlichkeit

$$p(\vec{\mathbf{x}}_t] \mid \vec{\mathbf{u}}_t, \vec{\mathbf{x}}_{t-1}) \quad (1.13)$$

zu formulieren. Das heißt es soll eine Funktion aufgestellt werden, die anhand der Vektoren $\vec{\mathbf{u}}_t$, $\vec{\mathbf{x}}_t$ und $\vec{\mathbf{x}}_{t-1}$ die Wahrscheinlichkeit dieses Ereignisses berechnet. Dafür wird nach Gleichung (1.12) die Werte der stochastisch unabhängigen Zufallsvariablen v_{err} , ω_{err} und γ_{err} berechnet. Die gesuchte Wahrscheinlichkeit ergibt sich dann aus deren gemeinsamer Verteilung

$$p(\vec{\mathbf{x}}_t, \vec{\mathbf{u}}_t, \vec{\mathbf{x}}_{t-1}) = p(\vec{\mathbf{x}}_t \mid \vec{\mathbf{u}}_t, \vec{\mathbf{x}}_{t-1}) = \varepsilon_v(v_{\text{err}}) \cdot \varepsilon_\omega(\omega_{\text{err}}) \cdot \varepsilon_\gamma(\gamma_{\text{err}}). \quad (1.14)$$

Da die direkte Umformung von Gleichung (1.7) zur expliziten Darstellung der gesuchten Fehlergrößen zu einem unhandlichen Ergebnis führt, wird eine indirekte Berechnung über den Momentanpol gewählt. Im ersten Schritt werden die Koordinaten des Momentanpols $\vec{\mathbf{c}}$ berechnet, wofür sich nach [1, S. 130]²

$$\begin{pmatrix} x_c \\ y_c \end{pmatrix} = \begin{pmatrix} \frac{x+\tilde{x}}{2} + \mu(y-\tilde{y}) \\ \frac{y+\tilde{y}}{2} + \mu(\tilde{x}-x) \end{pmatrix} \quad \mu = \frac{1}{2} \frac{(x-\tilde{x})\cos[\theta] + (y-\tilde{y})\sin[\theta]}{(y-\tilde{y})\cos[\theta] - (x-\tilde{x})\sin[\theta]} \quad (1.15)$$

ergibt. Woraus sich sowohl der Rotationsradius

$$r_c = \sqrt{(x-x_c)^2 + (y-y_c)^2} \quad (1.16)$$

als auch der auf der Kreisbahn zurückgelegte Winkel

$$\Delta\theta = \text{atan}\left[\frac{\tilde{y}-y_c}{\tilde{x}-x_c}\right] - \text{atan}\left[\frac{y-y_c}{x-x_c}\right] \quad (1.17)$$

berechnen lassen. Mithilfe der der Winkeldifferenz lässt sich wiederum auf die zurückgelegte Strecke

$$\Delta s = r_c \cdot \Delta\theta \quad (1.18)$$

schließend, welche zusammen auf den gestörten Stellvektor

$$\vec{\hat{u}} = \begin{pmatrix} \hat{v} \\ \hat{\omega} \end{pmatrix} = \frac{1}{\Delta t} \cdot \begin{pmatrix} \Delta s \\ \Delta\theta \end{pmatrix} \quad (1.19)$$

führen. Zuletzt fehlt der Orientierungsfehler $\hat{\gamma}$, der sich mithilfe von Gleichung (1.12) erschließen lässt.

$$\tilde{\theta} - \theta = \hat{\omega} \cdot \Delta t + \hat{\gamma} \cdot \Delta t \Leftrightarrow \hat{\gamma} = \frac{\tilde{\theta} - \theta}{\Delta t} - \hat{\omega}. \quad (1.20)$$

²Schreibweise für $\vec{\mathbf{x}}_t = (x \quad y \quad \theta)^T$, $\vec{\mathbf{x}}_{t+\Delta t} = (\tilde{x} \quad \tilde{y} \quad \tilde{\theta})^T$

Kapitel 2

Kartenerstellung

2.1 Occupancy-Grid-Mapping

In dem hiesigen Anwendungsfall sollen metrische Karten verwendet werden, um das Navigationsproblem lösen zu können. Ein passender Kartentyp sind die so genannten Occupancy-Grids, welche die Umgebung als 2- oder 3-dimensionales, diskretes Raster darstellen. Jeder Zelle der Karte wird eine Wahrscheinlichkeit zugeordnet, die wiedergibt, ob die Zelle belegt ist. Durch den stochastischen Charakter des Umgebungsmodells können Ungewissheiten bei der Kartographierung und anschließenden Navigation beachtet werden.

Mathematisch wird die Umgebung als diskrete Menge von binären Zufallsvariablen

$$M = \{m_i\} \quad (2.1)$$

beschrieben, die entweder den Zustand frei oder belegt annehmen können. Die Aufgabe des Kartographierungsalgorithmus besteht darin, eine Karte zu erstellen, wobei es sich um die a posteriori Wahrscheinlichkeit

$$p(M = \text{belegt} \mid \vec{z}_{1:t}, \vec{x}_{1:t})^1 \quad (2.2)$$

handelt. Für jede Zelle soll die Wahrscheinlichkeit, dass diese unter Beachtung aller bisheriger Sensorwerte $\vec{z}_{1:t}$ und aller Zustandswerte $\vec{x}_{1:t}$ belegt ist, ermittelt werden. Um dieses Problem zu lösen, wird als erster Ansatz ein Bayes-Filter für binäre Zufallsvariablen angeführt. Es werden die beiden folgenden Annahmen getroffen: Die Umgebung ist stationär, das heißt keine Objekte werden während der Kartenaufzeichnung verschoben. Somit kann der Algorithmus nicht genutzt werden, um dynamischen Hindernissen auszuweichen. Zweitens wird angenommen, dass die Wahrscheinlichkeiten der einzelnen Zellen unabhängig sind.

$$p(M \mid \vec{z}_{1:t}, \vec{x}_{1:t}) = \prod_i p(m_i \mid \vec{z}_{1:t}, \vec{x}_{1:t}). \quad (2.3)$$

Dadurch können die a posteriori Wahrscheinlichkeiten der Zellen separat berechnet werden. Allerdings kann diese Annahmen unter realen Umständen kaum verteidigt werden, da Hindernisse für gewöhnlich größer als eine einzelne Kartenzelle sind.

¹Im Folgenden wird die Wahrscheinlichkeit für $M = \text{belegt}$ bzw. $m_i = \text{belegt}$ als $p(M)$ bzw. $p(m_i)$ geschrieben. Die Wahrscheinlichkeiten für freie Zellen werden mit $p(\neg m_i)$ denotiert.

Für die Berechnung der Karte wird das logarithmische Verhältnis

$$l(x) = \log \left[\frac{p(m_i)}{1 - p(m_i)} \right] = \log \left[\frac{p(m_i)}{p(\neg m_i)} \right], \quad (2.4)$$

die bei binären Zufallsvariablen rechentechnische Vorteile mit sich bringen [1, S. 94 f]. Bei der Kartenaufzeichnung soll das logarithmische Verhältnis $l(m_i)_t$ am Zeitpunkt t anhand des vergangenen Wertes $l(m_i)_{t-1}$, des Messvektors \vec{z}_t und des Zustandsvektors \vec{x}_t für alle i Zellen der Karte bestimmt werden. Die gesuchte Wahrscheinlichkeit ergibt sich aus

$$p(x | \vec{z}_t) = \frac{1}{1 + e^{l(x)_t}}. \quad (2.5)$$

Für die Herleitung des Bayes-Filter wird zunächst der Fall betrachtet, dass die Zelle m_i belegt ist. Nach Bayes-Theorem folgt für die a posteriori Wahrscheinlichkeit

$$\begin{aligned} p(m_i | \vec{z}_{1:t}) &= p(m_i | \vec{z}_t, \vec{z}_{1:t-1}) \\ &= \frac{p(\vec{z}_t | m_i, \vec{z}_{1:t-1}) \cdot p(m_i | \vec{z}_{1:t-1})}{p(\vec{z}_t | \vec{z}_{1:t-1})} \\ &= \frac{p(\vec{z}_t | m_i) \cdot p(m_i | \vec{z}_{1:t-1})}{p(\vec{z}_t | \vec{z}_{1:t-1})}. \end{aligned} \quad (2.6)$$

Wie Wahrscheinlichkeit $p(\vec{z}_t | m_i)$ heißt Messmodell, da sie angibt, wie wahrscheinlich ein Messwert \vec{z}_t aus einer gegebenen Umgebung m_i folgt. Aus Bayes-Theorem folgt wiederum

$$p(\vec{z}_t | m_i) = \frac{p(m_i | \vec{z}_t) \cdot p(\vec{z}_t)}{p(m_i)} \quad (2.7)$$

und die anschließende Substitution in 2.6 liefert

$$p(m_i | \vec{z}_{1:t}) = \frac{p(m_i | \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(m_i | \vec{z}_{1:t-1})}{p(m_i) \cdot p(\vec{z}_t | \vec{z}_{1:t-1})}. \quad (2.8)$$

Analog ergibt sich für das komplementäre Ereignis $\neg m_i$

$$p(\neg m_i | \vec{z}_{1:t}) = \frac{p(\neg m_i | \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(\neg m_i | \vec{z}_{1:t-1})}{p(\neg m_i) \cdot p(\vec{z}_t | \vec{z}_{1:t-1})}. \quad (2.9)$$

Im nächsten Schritt folgt der Quotient der beiden Verteilungen

$$\begin{aligned} \frac{p(m_i | \vec{z}_{1:t})}{p(\neg m_i | \vec{z}_{1:t})} &= \frac{p(m_i | \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(m_i | \vec{z}_{1:t-1}) \cdot p(\neg m_i) \cdot p(\vec{z}_t | \vec{z}_{1:t-1})}{p(\neg m_i | \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(\neg m_i | \vec{z}_{1:t-1}) \cdot p(m_i) \cdot p(\vec{z}_t | \vec{z}_{1:t-1})} \\ &= \frac{p(m_i | \vec{z}_{1:t-1})}{p(\neg m_i | \vec{z}_{1:t-1})} \cdot \frac{p(m_i | \vec{z}_t)}{p(\neg m_i | \vec{z}_t)} \cdot \frac{p(\neg m_i)}{p(m_i)}, \end{aligned} \quad (2.10)$$

dessen Logarithmus das gesuchte Verhältnis liefert:

$$\begin{aligned} l(m_i)_t &\equiv \log \left[\frac{p(m_i | \vec{z}_{1:t})}{p(\neg m_i | \vec{z}_{1:t})} \right] \\ &= \underbrace{\log \left[\frac{p(m_i | \vec{z}_{1:t-1})}{p(\neg m_i | \vec{z}_{1:t-1})} \right]}_{=l(m_i)_{t-1}} - \underbrace{\log \left[\frac{p(\neg m_i)}{p(m_i)} \right]}_{=l(m_i)_{t=0} \equiv l_0} + \log \left[\frac{p(m_i | \vec{z}_t)}{p(\neg m_i | \vec{z}_t)} \right]. \end{aligned} \quad (2.11)$$

Somit setzt sich die gesuchte a posteriori Wahrscheinlichkeit aus drei Summanden zusammen. Bei dem Ersten handelt es sich um die Wahrscheinlichkeit $l(m_i)_{t-1}$ am vorherigen Abtastpunkt. Der Zweite gibt das Verhältnis der a priori Wahrscheinlichkeiten zum Zeitpunkt $t = 0$ wider und der letzte Teil ergibt sich aus dem logarithmischen Verhältnis von $p(m_i | \vec{z}_t)$, wobei es sich um ein inverses Messmodell handelt. Die Wahrscheinlichkeit $p(m_i | \vec{z}_t)$ wird von dem Entwickler vorgegeben und basiert auf der Charakteristik der Sensorik. Als Beispiel dient an dieser Stelle ein rudimentäres Modell für einen Laserscanner. Der Sensor gibt einen Vektor von Distanzmessungen zurück, die jeweils einen Messwinkel φ relativ zu dem Roboter zuzuordnen sind. Somit liegt ein Messbereich in Form eines Kegels mit dem Öffnungswinkel $\Delta\varphi$ vor, der durch die gemessenen Distanzen begrenzt wird. Im inversen Messmodell werden nun




Abbildung 2.1: Schematische Darstellung der Karten und des inversen Messmodells

drei Fälle unterschieden. Liegt eine Zelle außerhalb des Messkegels, kann keine Aussage über den Zustand der Zelle getroffen werden, weshalb der Wert l_0 zurückgegeben wird der in 2.11 eingesetzt zu

$$l(m_i)_t = l(m_i)_{t-1} + l_0 - l_0 = l(m_i)_{t-1} \quad (2.12)$$

führt. In dem Fall, dass die Zelle innerhalb des Messkegels liegt, wird geprüft auf welchem Messstrahl und in welcher Distanz die Zelle sich befindet. Ist der Abstand zwischen der Zelle und der gemessenen Distanz kleiner als ein Toleranzmaß α , wird angenommen, dass die Zelle belegt ist und ein entsprechender Wert l_{occupied} zurückgegeben. Liegt die Zelle mehr als α Einheiten vor der gemessenen Distanz, gilt sie als frei und das Modell liefert den Wert l_{free} .

Kapitel 3

ROS-Navigation-Stack

Bei dem ROS-Navigation-Stack handelt es sich um ein umfangreiches Software-Paket, das verschiedenste Funktionalitäten für das autonome Agieren eines Roboters bereitstellt. Von besonderem Interesse ist dabei das Paket *move_base*, welches bereits im Vorgängerprojekt für die Navigation des Roboters verwendet wurde. Funktional basiert das System auf einem zweischichtigen Planungskonzept: Zuerst berechnet ein globaler Planer anhand der vorgegebenen Karte einen optimalen Pfad zwischen Ausgangs- und Zielposition. Im Anschluss wird das Resultat an einen lokalen Planer übergeben, der die Stellgrößen des Roboters berechnet, um die geplante Trajektorie zu realisieren. Dabei werden neben dem optimalen Pfad ein lokaler Ausschnitt der Karte, Sensor- und Lokalisierungsdaten herangezogen, wodurch auch nicht vorhergesehene, dynamische Hindernisse bei der Planung beachtet werden können.

Im Gesamtkonzept spielen der lokale und globale Planer die entscheidenden Rollen, weshalb deren zu Grunde liegenden Algorithmen im Anschluss näher erläutert werden. Bei der Konfiguration ..

3.1 Funktionsprinzip des globalen Planers

Wie bereits erwähnt, wird die Navigationsaufgabe mithilfe zweier sukzessiver Planungsalgorithmen gelöst. Im ersten Schritt berechnet ein globaler Planer einen Weg zwischen der Ausgangs- und Zielposition, wofür die vorgegebene Karte herangezogen wird. Als Planungsalgorithmus werden im Navigation-Stack entweder Dijkstra- oder der A*-Algorithmus verwendet, die an dieser Stelle näher untersucht werden. Prinzipiell besteht die Aufgabe darin, einen Weg und Trajektorie zu ermitteln, die den Ausgangszustand des Roboters mit dem gewünschten Endzustand verbinden. Bei den gesuchten Pfaden handelt es sich um zeit- und ortskontinuierliche Kurven, woraus ein kontinuierlicher Raum von Lösungen resultiert, der nach einer optimalen durchsucht werden muss. Die Kontinuität des Suchraums stellt auf der Planungsseite eine immense Herausforderung dar, da eine unendliche Zahl von Möglichkeiten zur Verfügung stehen. **Viel zu schwammige Erklärung, kleinen Einschub über Probleme wie differenzialgleichungen und Gütefunktionale...** Um dieser Komplexität Herr zu werden wird der Suchraum diskretisiert und die Planungsaufgabe auf die Bestimmung einer Positionsfolge reduziert.

Allerdings wird die Diskretisierung des Raumes von mehr als einer reinen Vereinfachung des Suchproblems motiviert: Der globale Planer übernimmt lediglich den ersten Schritt bei der Berechnung der letztendlichen Trajektorie. Der lokale Planer berechnet anhand der globalen Sollkurve eine lokale Trajektorie, die in Form von Stellgrößen realisiert wird. Dabei werden neben der globalen Ortskurve auch aktuelle Sensor- und Lokalisierungsinformationen miteinbezogen, welche unter Umständen dazu führen können, dass der Roboter von der global geplanten Kurve abweicht. Insofern ergibt es wenig Sinn, bei der globalen Planung Ressourcen in eine unnötig genaue Trajektorie zu investieren; besonders dann, wenn noch nicht alle nötigen Informationen vorliegen. Für den Anfang genügt ein ungenauer, fehlerbehafteter Pfad, der die Anfangs- und Zielposition verbindet, wofür eine diskrete Darstellung des Suchraums vollkommen genügt. Des Weiteren stimmt die Forderung nach einer diskreten Darstellung des Suchraums mit den üblichen Darstellungsformen von metrischen Karten überein, denn diese repräsentieren die Umgebung in Form von diskreten Zellen.

Im Rahmen dieser Überlegung werden die vereinfachten Bedingungen zunächst in einer mathematischen Darstellung formuliert. Es wird angenommen, dass der Roboter in einer planen Umgebung manövriert, welche mittels einer zweidimensionalen Karte dargestellt werden kann. Hierfür wird eine metrische Karte verwendet, die den Raum in quadratische Zellen fixer Größe unterteilt. Die Positionen von Objekten innerhalb der Karten werden mithilfe des X- und Y-Indexes angegeben, wodurch die Positionsangaben von der Zellengröße entkoppelt werden. An dieser Stelle kann entweder ein deterministisches oder stochastisches Modell verwendet werden. Bei Erstem wird die Karte als Menge

$$M = \{m_{ij}\} \qquad m_{ij} \in \{0, 1\} \qquad (3.1)$$

dargestellt, wobei jede Zelle m_{ij} im belegten Fall den Wert 1 und ansonsten den Wert 0 annimmt. Bei den so genannten Occupancy-Grids handelt es sich eine stochastische Repräsentation: Für jede Zelle wird die Wahrscheinlichkeit angegeben, ob diese belegt ist.

Die Planungsaufgabe wird durch die Angabe einer Startposition \vec{x}_0 und einer Zielposition

\vec{x}_G definiert, wobei angenommen wird, dass sowohl \vec{x}_0 als auch \vec{x}_G freie Zellen sind. Zuletzt muss die Menge der möglichen Aktionen U spezifiziert werden. Hier wird eine weitere Vereinfachung vorgenommen. Die eigentlichen Stellgrößen des Roboters sind dessen Translations- und Rotationsgeschwindigkeit, welche sich allerdings auf zeit- und ortskontinuierliche Trajektorien führen. Da lediglich ortsdiskrete Pfade berechnet werden sollen, ergibt es Sinn, diskrete Positionsänderungen als Aktionen zu definieren. Beispielsweise kann die Verrückung um eine Zelle entlang der X- und Y-Richtung zugelassen werden. Da die Positionen in Form von Zellenindizes beschrieben werden, kann die Verrückung durch die Addition eines Vektors ausgedrückt werden, woraus die Aktionsmenge

$$U = \left\{ \vec{u}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \vec{u}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \vec{u}_3 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \vec{u}_4 = \begin{bmatrix} 0 \\ -1 \end{bmatrix} \right\} \quad (3.2)$$

resultiert. Von einem beliebigen Zustand \vec{x}_n ausgehend, kann mithilfe der Übergangsfunktion

$$\vec{x}_{n+1} = f(\vec{x}_n, \vec{u}) = \vec{x}_n + \vec{u} \quad (3.3)$$

der durch die Aktion \vec{u} erreichte Zustand \vec{x}_{n+1} ermittelt werden.

Stehen die Ausgangsposition \vec{x}_0 , die Zielposition \vec{x}_G , die Menge der zulässigen Zustände X , welche durch die Karte M definiert wird, und eine Aktionsmenge U zur Verfügung, können erste rudimentäre Planungsalgorithmen entwickelt werden. Die Aufgabe besteht darin eine Sequenz von Aktionen oder Zuständen zu bestimmen, welche die Positionen \vec{x}_0 und \vec{x}_G miteinander verbinden. Dabei spielt es keine Rolle, ob Aktionen oder wegzusammenhängende Zustände berechnet werden, da beide Darstellungsformen des Pfades mithilfe ineinander überführt werden können. Als erster Ansatz für die Lösung des Planungsproblems kann die so genannte Forward-Search nach [2, S. 28] verfolgt werden:

Listing 3.1: Ablauf der Forward-Search in Pseudocode

```

1  Q.Insert( $\vec{x}_0$ ) and mark  $\vec{x}_0$  as visited
2  while Q not empty do
3     $\vec{x}_n = Q.GetFirst()$ 
4    if  $\vec{x}_n = \vec{x}_G$ 
5      return SUCCESS
6    forall  $\vec{u} \in U$ 
7       $\vec{x}_{n+1}$  not visited
8      Mark  $\vec{x}_{n+1}$  as visited
9      Q.Insert( $\vec{x}_{n+1}$ )
10 return FAILURE

```

Der Algorithmus basiert auf einer Datenstruktur Q , deren Funktionsprinzip die Charakteristik des Suchalgorithmus maßgeblich prägt. Bei der Initialisierung des Algorithmus wird die Anfangsposition \vec{x}_0 in die Datenstruktur eingefügt. Anschließend wird in einer Schleife die Struktur ausgelesen, wo zuerst geprüft wird, ob der aktuelle Zustand \vec{x}_n der gesuchten Zielposition \vec{x}_G gleicht und gegebenenfalls terminiert die Suche. Wurde das Ziel noch nicht erreicht, werden alle möglichen Aktionen \vec{u} auf den aktuellen Zustand \vec{x}_n angewandt, wodurch jeweils ein neuer Zustand \vec{x}_{n+1} erzeugt wird. Falls der neue Zustand \vec{x}_{n+1} noch nicht geprüft wurde, wird er ebenfalls in die Datenstruktur Q eingefügt. Dadurch wird der Suchraum der möglichen Zustände systematisch durchsucht, wobei eine mehrmalige Prüfung des gleichen Zustandes durch eine Markierung verhindert wird. Wenn die Datenstruktur Q keine

Elemente enthält, wurden alle möglichen Zustände geprüft; folglich kann das gewünschte Ziel nicht von der gegebenen Anfangsposition erreicht werden.

Das Funktionsprinzip der Datenstruktur Q gibt die Reihenfolge vor, in der die neu erschlossenen Zustände überprüft werden, wodurch die Suchstrategie festgelegt wird. Arbeitet Q nach dem FIFO-Prinzip, wird der Suchraum zuerst in der Breite und anschließend in der Tiefe erforscht. Als Beispiel dient eine beliebige Startposition \vec{x}_0 und die bereits genannte Aktionsmenge

$$U = \left\{ \vec{u}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \vec{u}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \vec{u}_3 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, mVecu_4 = \begin{bmatrix} 0 \\ -1 \end{bmatrix} \right\}. \quad (3.2)$$

Die folgenden Zustände ergeben sich ebenfalls nach

$$\vec{x}_{n+1} = f(\vec{x}_n, \vec{u}) = \vec{x}_n + \vec{u}. \quad (3.3)$$

Folglich entspricht die Menge der am Iterationsschritt 1 möglichen Zustände dem Abbild

$$X_1 = f(\vec{x}_0, U) = \{\vec{x}_0 + \vec{u} \mid \vec{u} \in U\}. \quad (3.4)$$

Analog kann die Menge der möglichen Zustände an einem beliebigen Schritt $n + 1$ durch das Abbild

$$X_{n+1} = f(X_n, U) \quad (3.5)$$

bestimmt werden. Angenommen die Suche wird von einem beliebigen Startzustand \vec{x}_0 begonnen, so wird im ersten Schleifendurchlauf das Abbild X_1 bestimmt und in die Datenstruktur eingefügt. Arbeite diese nun nach dem FIFO-Prinzip werden in den folgenden Durchläufen die Elemente der Menge X_1 bearbeitet, wodurch die Menge X_2 berechnet und in die Datenstruktur eingefügt werden. Da die Elemente von X_2 aber nach denen von X_1 in die Schlange eingefügt werden, wird sichergestellt, dass zuerst alle Elemente von X_1 geprüft werden, bevor die Bearbeitung von X_2 stattfindet. Aus diesem Grund wird diese Suchstrategie als Breadth-First bezeichnet, da zuerst alle Möglichkeiten eines Iterationsschrittes geprüft werden, bevor die nachfolgende Iteration betrachtet wird. Stell man den Suchraum als Baum dar, wird die Bedeutung der Begriffe Tiefe und Breite deutlich.

Mit der Breadth-First-Search liegt ein systematischer Ansatz vor, der einen Pfad zum Ziel findet, falls ein solcher existiert. Außerdem ist recht leicht ersichtlich, dass der Algorithmus immer auf einen möglichst kurzen Lösungspfad führt.

Beispiel zeigen, Breiten-Suche Lösung zeigen

Die komplementäre Strategie wird als Depth-First-Search bezeichnet, bei der zuerst die Tiefe des Suchbaums erforscht wird, bevor parallele Zweige überprüft werden. Die Umsetzung der Depth-First-Search erfolgt indem die Datenstruktur Q als LIFO-Speicher implementiert wird. Dadurch kann im Vergleich zu der Breadth-First-Search die Suchzeit unter Umständen drastisch reduziert werden, allerdings resultieren für gewöhnlich längere Pfade. Wenn die Anzahl der Iterationsschritte oder die Menge der zulässigen Zustände begrenzt sind, wird auch die Depth-First-Search zu einem systematischen Suchansatz. Das heißt der Algorithmus stößt garantiert auf ein Ergebnis, falls ein solches existiert. Durch das LIFO-Prinzip der Datenstruk-

tur wird das Ergebnis der zuletzt ausgeführten Aktion unmittelbar weiterverfolgt. Dadurch bekommt die Reihenfolge, in der die möglichen Aktionen \vec{u} appliziert werden, eine zentrale Bedeutung, da dadurch die Suchrichtung vorgegeben wird. Die folgenden Abbildungen zeigen die Auswirkungen einer veränderten Aktionsreihenfolge anhand des Korridorbeispiels.

Bilder einfügen mit Depth-First und verschiedenen Reihenfolgen

Prinzipiell kann die Suche - unabhängig von der gewählten Strategie - auch von der Zielposition ausgehend beginnen. In diesem Fall wird von einer so genannten Backwards-Search gesprochen. Werden Forward- und Backward-Search simultan verfolgt, resultiert die so genannten Bidirectional-Search. Diese Adaptionen können unter Umständen verkürzte Suchzeiten liefern, werden an dieser Stelle aber nicht weiterverfolgt, da dieser Aspekt bei dem hiesigen Anwendungsfall nicht zum Tragen kommt.

3.2 Optimale Suche und Planung

In den bisherigen Suchalgorithmen bestand die Aufgabe lediglich darin, einen Pfad zwischen Ausgangs- und Zielposition zu finden. Dies hatte unter anderem zur Folge, dass starke Unterschiede zwischen den Lösungen der verschiedenen Ansätze resultierten. Besonders bei der Depth-First-Search kamen zum Teil äußerst umständliche Pfade zu Stande. Aus diesem Grund soll im nächsten Schritt eine Bewertung der Lösungsmöglichkeiten eingeführt werden, die genutzt wird, um einen optimalen Pfad im Sinne dieses Gütekriteriums zu ermitteln. Bei der globalen Pfadplanung sollen prinzipiell zwei Aspekte beachtet werden: Einerseits soll der resultierende Pfad möglichst kurz sein, andererseits soll ein gewisser Abstand zu belegten Zellen der Karte gehalten werden bzw. die belegten Zellen sollen von dem Pfad nicht durchkreuzt werden. Um diese Vorgaben in einem Gütekriterium auszudrücken, wird die Karte in eine sogenannte Kostenkarte transformiert. Diese ordnet jeder Zelle einen Aufwand zu, wodurch es möglich wird verschiedenen Pfade zu bewerten und miteinander zu vergleichen. Die Kosten eines Pfades ergeben sich aus der Summe der enthaltenen Zellen. Ein Beispiel für eine mögliche Bewertung der Zellen ordnet jeder freien Zelle den Aufwand 1 und jeder belegten Zelle den Wert ∞ zu. Durch letzteren wird sichergestellt, dass belegte Zellen vermieden werden. Die Gewichtung von freien Zellen führt dazu, dass kürzere Pfade mit geringeren Kosten verbunden sind. Eine Möglichkeit, um einen im Kontext der Kostenkarte optimalen Pfad zu berechnen, stellt Dijkstra's Algorithmus dar. Dieser gleicht im Grundprinzip den bisher betrachteten Vorgehensweise, mit dem Unterschied, dass die Datenstruktur Q so sortiert werden, dass das Element mit dem aktuell geringsten Kostenaufwand am Anfang der Liste steht. Zusätzlich muss in dem Fall, dass ein Zustand geprüft wird, der bereits besucht worden ist, verglichen werden, welcher der beiden Pfade den geringeren Aufwand benötigt.

Liste mit Pseudocode des Algorithmus

Applikationsbeispiel Korridor, Kostenkarte abbilden

3.2.1 A*

Indem bei Dijkstra's Algorithmus die Liste Q nach aufsteigenden Kosten sortiert wird, kann gesichert werden, dass die Suche zu einem optimalen Ergebnis führt. Allerdings bringt dieses Vorgehen einen zum Teil unnötigen Suchaufwand mit sich, was recht leicht illustriert werden

kann: Um möglichst kurze Pfade zu erhalten, wurde jeder weitere Schritt mit einem fixen Aufwand bewertet. Dies hat zur Folge, dass die kürzesten Pläne an den Anfang der Liste rücken, inklusive der Pfade, die entweder zu kurz sind, um das Ziel überhaupt erreichen zu können, als auch solche die sich in eine falsche Richtung bewegen. Insofern erzwingt die sortierte Datenstruktur eine Breitensuche, da kurze Pfade fälschlicherweise - zumindest teilweise fälschlicherweise - mit weniger Aufwand verbunden sind.

Ein Ansatz, um dieser Problematik vorzubeugen, stellt der A^* Algorithmus dar, der nach dem identischen Grundprinzip wie Dijkstra's Algorithmus arbeitet. Lediglich das Gewichtungskonzept der Pläne unterscheiden die beiden Vorgehensweisen. Für jede Position \vec{x}_n existiert ein optimaler Pfad, welcher \vec{x}_n mit der Zielposition \vec{x}_G verbindet. Die Kosten des optimalen Pfades werden von der Funktion $G^*(\vec{x}_n)$ beschrieben. Die Idee des A^* Algorithmus besteht darin, neben den Kosten des Pfades von \vec{x}_0 zu \vec{x}_n auch die verbleibenden Kosten nach \vec{x}_G zu beachten. Dadurch werden kürzere Pfade nicht mehr aus Prinzip bevorzugt, sondern lediglich dann, wenn ihre erwarteten Kosten bis zum Ziel ebenfalls gering sind. Da die optimalen Kosten $G^*(\vec{x}_n)$ nicht bekannt sind müssen sie mithilfe approximiert werden, wofür eine heuristische Schätzung $G(\vec{x}_n)$ eingeführt wird. An die Heuristik ist die Bindung geknüpft, dass die geschätzten Kosten $G(\vec{x}_n)$ stets kleiner oder gleich der optimalen Kosten $G^*(\vec{x}_n)$ sind:

$$G(\vec{x}_n) \leq G^*(\vec{x}_n) \quad \forall \vec{x}_n \in X. \quad (3.6)$$

Als Beispiel wird wieder die Navigation durch den Korridor betrachtet. Hier wurde jede Verrückung mit dem Aufwand 1 gewichtet, woraus folgt, dass die Kosten zwischen \vec{x}_n und \vec{x}_G mindestens gleich der absoluten Differenzen zwischen den X- und Y-Koordinaten der beiden Positionen sein muss. Im Falle, dass ein Hindernis den direkten Weg zwischen \vec{x}_n und \vec{x}_G versperrt nehmen die optimalen Kosten $G^*(\vec{x}_n)$ weiter zu, weshalb

$$G(\vec{x}_n) = |x_n - x_G| + |y_n - y_G| \leq G^*(\vec{x}_n) \quad \forall \vec{x}_n \in X \quad (3.7)$$

stets gilt. Somit stellt $G(\vec{x}_n)$ eine legitime Approximation der optimalen Kosten $G^*(\vec{x}_G)$ dar. Wird diese Forderung an die Kostenschätzung eingehalten, kann bewiesen werden, dass der A^* Algorithmus stets eine optimale Lösung findet, insofern diese existiert [2, S. 32][3, 4]. Bei der - recht konservativen - Schätzung $G(\vec{x}_n) = 0$ geht das A^* Verfahren in Dijkstra's Algorithmus über.

Beispiel

Literaturverzeichnis

- [1] Sebastian, Thrun; Wolfram, Burgard; Dieter Fox: „Probabilistic Robotics“, 1. Auflage, Massachusetts Institute of Technology 2006, MIT Press
- [2] LaValle, Steven M. „Planning Algorithms“, 1. Auflage, Cambridge 2006, Cambridge University Press
- [3] Pearl, J. „Heuristics“, Addison-Wesley, 1984
- [4] Fikes, R. E.; Nilsson, N. J. „STRIPS: A new approach to the application of theorem proving.“Artificial Intelligence Journal, 1971