

Inhaltsverzeichnis

1	Stochastische Modelle in der Robotik	1
1.1	Geschwindigkeitsbasiertes Bewegungsmodell	3
1.2	Messmodell	6
2	Kartenerstellung	9
2.1	Occupancy-Grid-Mapping	9
3	ROS-Navigation-Stack	13
3.1	Funktionsprinzip des globalen Planers	14
3.1.1	Forward-Search: Breiten Suche	15
3.1.2	Forward-Search: Tiefensuche	17
3.1.3	Optimale Suche und Planung	18
3.2	Lokaler Planer: Dynamic Window Approach	21
3.2.1	Anwendungsbeispiel	23
4	Stochastische Filter	27
4.1	Kontinuierliches Bayes Filter	27
4.2	Diskretes Bayes-Filter und Histogramm-Filter	32
4.3	Partikel-Filter	33
5	ROS-Implementierung	35
5.1	Überblick und Gesamtkonzept	36
5.2	Globaler Planer	37
5.3	Kostenkarten	38
5.4	Lokaler Planer	39
	Literaturverzeichnis	41

Kapitel 1

Stochastische Modelle in der Robotik

Jede elaborierte Methoden erfordert einen Rahmen, in dem sie erarbeitet, formuliert und optimiert werden kann. In technischen Aufgabenstellung erfüllt die Mathematik diese Forderung, weshalb die Gegebenheiten und Probleme des hiesigen Anwendungsfall zunächst in einem mathematischen Kontext dargestellt werden. Denn nur von dieser Basis ausgehend, besteht die Aussicht auf eine elegante und ansprechende Lösung.

Wie alle Probleme der Robotik, kann auch die autonome Navigation im entferntesten Sinne als Interaktion eines Roboters mit seiner Umwelt aufgefasst werden. Anhand von gesammelten Informationen muss das System eine Entscheidung über seine zukünftigen Aktionen treffen, wobei ein entferntes Ziel ohne ungewollte Kollisionen angesteuert werden soll. Für diese Aufgaben spielen drei Größen eine fundamentale Rolle. Zunächst muss die Position des Roboters beachtet werden, welche in dem Positionsvektor $\vec{x}(t) \equiv \vec{x}_t$ erfasst wird. Mithilfe von Sensoren sammelt der Roboter Informationen über seine Umgebung, die in dem Messvektor \vec{z}_t zusammengefasst werden. Anhand der Mess- und Positionsvektoren wird über die nächste Aktion des Roboters entschieden, die in dem Steuervektor \vec{u}_t ausgedrückt wird. Die exakte Form der Positions-, Mess- und Steuervektoren hängt von dem gegebenen Anwendungsfall und gewählten Modellformen ab, die im Folgenden näher erläutert werden.

In anderen Fachgebieten, die sich mit der Planung von Steuersignalen bzw. -sequenzen beschäftigen - wie z.B. die Regelungstechnik -, haben sich modellbasierte Methoden bewährt. Zunächst wird auf Basis von physikalischen Gegebenheiten der Zusammenhang zwischen Steuer-, Zustands- und Messvektor hergeleitet, der anschließend genutzt wird, um eine Regelstrategie zu formulieren. Der resultierende Algorithmus berechnet die Stellgröße \vec{u}_t , wofür die aktuellen Mess- und Zustandsvektoren herangezogen werden. Insofern liegt es nahe modellbasierte Ansätze auch bei Problemen der Robotik zu verfolgen. Allerdings kommt dort die ungemeine Komplexität der Problemstellung zu tragen, die sich recht leicht am Beispiel der Navigation illustrieren lässt: Als erstes muss ein Modell für den Einfluss des Stellvektors \vec{u}_t auf den Positionsvektor \vec{x}_t erstellt werden. Bei mobilen Roboterplattformen handelt es sich um mechanische Systeme mit mehreren Freiheitsgraden, womit die analytische Modellbildung zwar möglich, jedoch mit einem beachtlichen Aufwand verbunden ist. Spätestens bei der Modellierung der Sensoren werden die Grenzen des Möglichen erreicht: Soll beispielsweise

die Position des Roboters mithilfe von Stereokameras erfasst werden kann praktisch kaum ein exaktes, deterministisches Modell für diesen Vorgang erfasst werden, da er von zu vielen unbekannten Einflussfaktoren betroffen ist. Zuletzt kann die Pfadplanung per Definition nicht anhand eines deterministischen Modells erfolgen, da der Roboter dynamischen Hindernissen ausweichen soll, deren Form, Bewegung in der Aufgabenstellung nicht näher spezifiziert werden.

Aus diesen Gründen haben sich in der Robotik stochastische Modellformen etabliert, wobei recht simple Ausgangsmodelle verwendet werden, die um Zufallsvariablen ergänzt werden, um die Ungenauigkeiten und Ungewissheiten des Modells zu repräsentieren. Das Ziel besteht nicht mehr darin konkrete Aussagen über den Verlauf von Zustandsgrößen zu treffen, wie dies z.B. bei einer Zustandsraumdarstellung der Form

$$\vec{\mathbf{x}}(n+1) = \underline{\mathbf{A}} \cdot \vec{\mathbf{x}}(n) + \underline{\mathbf{B}} \cdot \vec{\mathbf{u}}(n) \quad (1.1)$$

erfolgt. Vielmehr soll mithilfe des Modells eine bedingte Wahrscheinlichkeit

$$p(\vec{\mathbf{x}}(n+1) \mid \vec{\mathbf{x}}(n), \vec{\mathbf{u}}(n)) \quad (1.2)$$

berechnet werden. Im Anschluss können die Methoden der Wahrscheinlichkeitstheorie genutzt werden, um Filter- und Planungsalgorithmen zu entwerfen. Um einen ersten Eindruck für diese Modellformen zu erhalten, werden im Anschluss rudimentäre Ansätze für ein Bewegungs- und Sensormodell vorgestellt.

1.1 Geschwindigkeitsbasiertes Bewegungsmodell

¹ Als erstes Beispiel wird ein stochastisches Modell für die Roboterbewegung entworfen, wobei anhand des vergangenen Positionsvektor \vec{x}_{t-1} und des aktuellen Steuervektors \vec{u}_t die Wahrscheinlichkeitsverteilung des aktuellen Positionsvektors \vec{x}_t

$$p(\vec{x}_t \mid \vec{u}_t, \vec{x}_{t-1}) \quad (1.3)$$

bestimmt werden soll. In diesem Fall wird lediglich eine planare Bewegung betrachtet, das heißt der Roboter bewegt sich in der xy-Ebene. Der Positionsvektor setzt sich somit aus den drei Größen

$$\vec{x} = \begin{pmatrix} x \\ y \\ \theta \end{pmatrix} \quad (1.4)$$

zusammen, welche die x-/y-Position und Ausrichtung des Roboters wiedergeben. θ gibt dabei den Winkel zwischen der x-Koordinatenachse und der Blickrichtung des Roboters an. Der Steuervektor \vec{u} gibt die aktuelle Translations- und Rotationsgeschwindigkeit

$$\vec{u} = \begin{pmatrix} v \\ \omega \end{pmatrix} \quad (1.5)$$

des Roboters an, wobei angenommen wird, dass die beiden Geschwindigkeiten zwischen zwei Abtastpunkten t und $t+1$ konstant sind. v beschreibt die Translationsgeschwindigkeit in Blickrichtung, während ω die Änderung des Blickwinkels θ wiedergibt. Unter der Annahme dass die Geschwindigkeiten \vec{u} in dem Intervall $[t-1, t]$ zwischen zwei Abtastpunkten konstant bleibt, kann die Bewegung als Rotation um einen konstanten Momentanpol $\vec{c} = (x_c \ y_c)^T$ betrachtet werden.




Abbildung 1.1: Darstellung des Momentanpols am Zeitpunkt t [1, S. 126]

Für den Radius gilt

$$r = \left| \frac{v}{\omega} \right|, \quad (1.6)$$

wobei zu beachten ist, dass der Radius für eine Winkelgeschwindigkeit $\omega = 0$ gegen unendlich konvergiert, was wiederum einer reinen Translation entspricht. Aus dem Positionsvektors des Roboters \vec{x}_t an dem Zeitpunkt t kann der Momentanpol für die folgende Abtastperiode

¹Das Bewegungsmodell und dessen Herleitung stammen aus [1, S. 121 ff]

berechnet werden:

$$\begin{pmatrix} x_c \\ y_c \end{pmatrix} = \begin{pmatrix} x(t) - \frac{v}{\omega} \cdot \sin[\theta] \\ y(t) + \frac{v}{\omega} \cdot \cos[\theta] \end{pmatrix} \leftrightarrow \begin{pmatrix} x(t) \\ y(t) \end{pmatrix} = \begin{pmatrix} x_c + \frac{v}{\omega} \cdot \sin[\theta] \\ y_c - \frac{v}{\omega} \cdot \cos[\theta] \end{pmatrix}. \quad (1.7)$$

Im nächsten Schritt wird die Bewegung über eine Abtastperiode Δt betrachtet, wodurch der Roboter um die Winkeldifferenz $\Delta t \cdot \omega$ auf dem Kreisbogen wandert. Nach 1.7 folgt für den Positionsvektor am Zeitpunkt $t + \Delta t$

$$\begin{aligned} \begin{pmatrix} x(t + \Delta t) \\ y(t + \Delta t) \\ \theta(t + \Delta t) \end{pmatrix} &= \begin{pmatrix} x_c + \frac{v}{\omega} \cdot \sin[\theta(t) + \omega \cdot \Delta t] \\ y_c - \frac{v}{\omega} \cdot \cos[\theta(t) + \omega \cdot \Delta t] \\ \theta(t) + \omega \cdot \Delta t \end{pmatrix} \\ &= \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix} + \begin{pmatrix} -\frac{v}{\omega} \cdot \sin[\theta(t)] + \frac{v}{\omega} \cdot \sin[\theta(t) + \omega \cdot \Delta t] \\ \frac{v}{\omega} \cdot \cos[\theta(t)] - \frac{v}{\omega} \cdot \cos[\theta(t) + \omega \cdot \Delta t] \\ \omega \cdot \Delta t \end{pmatrix}. \end{aligned} \quad (1.8)$$

Bisher wurden lediglich deterministische Bewegungen betrachtet. Um nun mögliche Fehler des Steuervektors $\vec{\mathbf{u}}$ zu beachten, werden die störbehafteten Geschwindigkeiten

$$\vec{\mathbf{u}} = \begin{pmatrix} \hat{v} \\ \hat{\omega} \end{pmatrix} = \begin{pmatrix} v + v_{\text{err}} \\ \omega + \omega_{\text{err}} \end{pmatrix} \quad (1.9)$$

eingeführt. Die Zufallsvariablen v_{err} und ω_{err} dienen der Fehlermodellierung und ihre Wahrscheinlichkeitsverteilungen ε_v und ε_ω werden dem Anwendungsfall nach angepasst. Einsetzen des stochastischen Steuervektors $\vec{\mathbf{u}}$ liefert

$$\begin{pmatrix} x(t + \Delta t) \\ y(t + \Delta t) \\ \theta(t + \Delta t) \end{pmatrix} = \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix} + \begin{pmatrix} -\frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t)] + \frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t)] - \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \hat{\omega} \cdot \Delta t \end{pmatrix}. \quad (1.10)$$

In diesem Modell wurden lediglich zwei Zufallsvariablen eingeführt, um die Störung von drei Positionsvariablen zu modellieren. Aus diesem Grund entsteht eine ungewollte stochastische Abhängigkeit zwischen den Elementen des Positionsvektors $\vec{\mathbf{x}}(t + \Delta t)$. Dieses Problem wird behoben, indem eine dritte Zufallsvariable

$$\gamma_{\text{err}} \equiv \hat{\gamma} \quad (1.11)$$

eingeführt wird, die zu einer zusätzlichen Störung der Orientierung $\theta(t + \Delta t)$ in Form von

$$\begin{pmatrix} x(t + \Delta t) \\ y(t + \Delta t) \\ \theta(t + \Delta t) \end{pmatrix} = \begin{pmatrix} x(t) \\ y(t) \\ \theta(t) \end{pmatrix} + \begin{pmatrix} -\frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t)] + \frac{\hat{v}}{\hat{\omega}} \cdot \sin[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t)] - \frac{\hat{v}}{\hat{\omega}} \cdot \cos[\theta(t) + \hat{\omega} \cdot \Delta t] \\ \hat{\omega} \cdot \Delta t + \hat{\gamma} \cdot \Delta t \end{pmatrix} \quad (1.12)$$

führt. Die Aufgabe besteht jetzt darin, ein Bewegungsmodell in Form der bedingten Wahrscheinlichkeit

$$p(\vec{\mathbf{x}}_t \mid \vec{\mathbf{u}}_t, \vec{\mathbf{x}}_{t-1}) \quad (1.13)$$

zu formulieren. Das heißt es soll eine Funktion aufgestellt werden, die anhand der Vektoren $\vec{\mathbf{u}}_t$,

\vec{x}_t und \vec{x}_{t-1} die Wahrscheinlichkeit dieses Ereignisses berechnet. Dafür wird nach Gleichung (1.12) die Werte der stochastisch unabhängigen Zufallsvariablen v_{err} , ω_{err} und γ_{err} berechnet. Die gesuchte Wahrscheinlichkeit ergibt sich dann aus deren gemeinsamer Verteilung

$$p(\vec{x}_t, \vec{u}_t, \vec{x}_{t-1}) = p(\vec{x}_t \mid \vec{u}_t, \vec{x}_{t-1}) = \varepsilon_v(v_{\text{err}}) \cdot \varepsilon_\omega(\omega_{\text{err}}) \cdot \varepsilon_\gamma(\gamma_{\text{err}}). \quad (1.14)$$

Da die direkte Umformung von Gleichung (1.7) zur expliziten Darstellung der gesuchten Fehlergrößen zu einem unhandlichen Ergebnis führt, wird eine indirekte Berechnung über den Momentanpol gewählt. Im ersten Schritt werden die Koordinaten des Momentanpols \vec{c} berechnet, wofür sich nach [1, S. 130]²

$$\begin{pmatrix} x_c \\ y_c \end{pmatrix} = \begin{pmatrix} \frac{x+\tilde{x}}{2} + \mu(y-\tilde{y}) \\ \frac{y+\tilde{y}}{2} + \mu(\tilde{x}-x) \end{pmatrix} \quad \mu = \frac{1}{2} \frac{(x-\tilde{x})\cos[\theta] + (y-\tilde{y})\sin[\theta]}{(y-\tilde{y})\cos[\theta] - (x-\tilde{x})\sin[\theta]} \quad (1.15)$$

ergibt. Woraus sich sowohl der Rotationsradius

$$r_c = \sqrt{(x-x_c)^2 + (y-y_c)^2} \quad (1.16)$$

als auch der auf der Kreisbahn zurückgelegte Winkel

$$\Delta\theta = \text{atan}\left[\frac{\tilde{y}-y_c}{\tilde{x}-x_c}\right] - \text{atan}\left[\frac{y-y_c}{x-x_c}\right] \quad (1.17)$$

berechnen lassen. Mithilfe der der Winkeldifferenz lässt sich wiederum auf die zurückgelegte Strecke

$$\Delta s = r_c \cdot \Delta\theta \quad (1.18)$$

schließend, welche zusammen auf den gestörten Stellvektor

$$\vec{\hat{u}} = \begin{pmatrix} \hat{v} \\ \hat{\omega} \end{pmatrix} = \frac{1}{\Delta t} \cdot \begin{pmatrix} \Delta s \\ \Delta\theta \end{pmatrix} \quad (1.19)$$

führen. Zuletzt fehlt der Orientierungsfehler $\hat{\gamma}$, der sich mithilfe von Gleichung (1.12) erschließen lässt.

$$\tilde{\theta} - \theta = \hat{\omega} \cdot \Delta t + \hat{\gamma} \cdot \Delta t \Leftrightarrow \hat{\gamma} = \frac{\tilde{\theta} - \theta}{\Delta t} - \hat{\omega}. \quad (1.20)$$

²Schreibweise für $\vec{x}_t = (x \ y \ \theta)^T$, $\vec{x}_{t+\Delta t} = (\tilde{x} \ \tilde{y} \ \tilde{\theta})^T$

1.2 Messmodell

Als weiteres Beispiel wird ein stochastisches Messmodell vorgestellt, das später bei der Lokalisierung wiederverwendet wird. Das Ziel des Messmodells ist es den Zusammenhang zwischen einem Zustandsvektor \vec{x}_t und einem Messvektor \vec{z}_t in Form der bedingten Wahrscheinlichkeit

$$p(\vec{z}_t | \vec{x}_t) \quad (1.21)$$

herzustellen. Die Verteilung sagt aus, mit welcher Wahrscheinlichkeit ein Messvektor \vec{z}_t von einer vorgegebenen Position \vec{x}_t aus erzielt wird. Das Messmodell dient als Paradebeispiel dafür, wie heuristische Argumente in stochastische Modelle einfließen können. Unabhängig von dem exakten Sensor wird angenommen, dass es sich um ein auf Messstrahlen basiertes Messprinzip handelt. Das heißt der Messvektor \vec{z}_t setzt sich aus mehreren Messwerten z_t^k zusammen, die jeweils die auf einem Strahl gemessene Distanz wiedergeben.

Als erste Störgröße wird ein gewöhnliches Messrauschen eingeführt, das als normal verteilt angenommen wird. Der Mittelwert der Verteilung ist die tatsächliche Distanz auf dem Messstrahl, die mit z_t^{k*} denotiert wird. Als zweiter Parameter muss die Varianz σ_{hit} festgelegt werden, die angibt wie stark der Messwert von dem Rauschen beeinflusst wird. Somit ergibt sich als Modell für das Sensorrauschen

$$p_{\text{hit}}(z_t^k | \vec{x}_t) = \begin{cases} \eta \cdot \mathcal{N}(z_t^k, z_t^{k*}, \sigma_{\text{hit}}^2) & \forall z_t^k \in [0, z_{\text{max}}] \\ 0 & \forall z_t^k \notin [0, z_{\text{max}}] \end{cases} \quad (1.22)$$

Die Messwerte werden außerdem von unerwarteten Objekten beeinflusst. Angenommen es liegt eine Karte der Umgebung vor und es bewegt sich ein Mensch innerhalb des Raumes. Wenn der Mensch nun die Messstrahlen unterbricht tritt ein geringerer Messwert als anhand der Karte erwartet ein. Im Allgemeinen gilt, dass im Falle von Störungen durch unerwartete Objekte die Messwerte lediglich kleiner, aber niemals größer werden. Des Weiteren nimmt die Wahrscheinlichkeit, dass ein Messwert von einem Objekt beeinflusst wird mit zunehmendem Messdistanz ab. Für das Modell wird eine exponentiell abfallende Verteilung

$$p_{\text{short}}(z_t^k | \vec{x}_t) = \begin{cases} \eta \cdot \lambda_{\text{short}} \cdot e^{-\lambda_{\text{short}} \cdot z_t^k} & \forall z_t^k \in [0, z_t^{k*}] \\ 0 & \forall z_t^k \notin [0, z_t^{k*}] \end{cases} \quad (1.23)$$

gewählt, wobei λ_{short} als wählbarer Parameter die Häufigkeit der Störungen widerspiegelt.

Als dritte Ursache für Messfehler wird das sporadische Versagen des Sensors herangezogen. Derartige Phänomene können bei Laserscannern auftreten, wenn beispielsweise schwarze Oberflächen die Strahlen vollständig absorbieren. Ähnliche Probleme werden bei Sonarsensoren durch Interferenz oder schallabsorbierende Medien hervorgerufen. Unabhängig von dem Messprinzip des Sensors werden in all den beschriebenen Fällen - fälschlicherweise - maximale Distanzen gemessen, wodurch die Verteilung

$$p_{\text{max}}(z_t^k | \vec{x}_t) = \begin{cases} 1 & \forall z = z_{\text{max}} \\ 0 & \forall z \neq z_{\text{max}} \end{cases} \quad (1.24)$$

motiviert wird. Die Aussage von dieser Verteilung ist ein bisschen Banane, wenn wenn der

Messwert den maximal Möglichen anzeigt, ist die dass 100 Prozent der Fall, ansonsten nicht? Oder ist es so zu verstehen, dass ein maximaler Messwert zu 100 Prozent den Fall von Messfehler bedeutet? Dann müsste ich die Interpretation der anderen Verteilungen nochmal überdenken

Als letzter und absurdester Fall werden rein zufällig falsche Phänomene betrachtet. Als Argument dient die Beobachtung, dass es unerklärliche Messwerte gibt, die - zu Gunsten der Simplität - durch eine Gleichverteilung der Form

$$p_{\text{rand}}(z_t^k | \vec{\mathbf{x}}_t) = \begin{cases} \frac{1}{z_{\text{max}}} & \forall z_t^k \in [0, z_{\text{max}}] \\ 0 & \forall z_t^k \notin [0, z_{\text{max}}] \end{cases} \quad (1.25)$$

repräsentiert werden. Es liegt schließlich nahe das komplexeste aller Probleme durch die simpelste aller Darstellung zu beschreiben. An diesem Beispiel wird deutlich, dass heuristische Einflüsse in stochastischen Modellen auch mit variierendem Elan verteidigt werden.

Die gesuchte Wahrscheinlichkeit $p(z_t^k | \vec{\mathbf{x}}_t)$ wird aus Summe der vier Verteilung berechnet, wobei diese mit den Faktoren z_{hit} , z_{short} , z_{max} und z_{rand} gewichtet werden. Die Gewichtung erlauben es dem Anwender, die Heuristiken nach ihrer Glaubhaftigkeit zu bewerten.

$$p(z_t^k | \vec{\mathbf{x}}_t) = \begin{bmatrix} z_{\text{hit}} & z_{\text{short}} & z_{\text{max}} & z_{\text{rand}} \end{bmatrix} \cdot \begin{bmatrix} p_{\text{hit}}(z_t^k | \vec{\mathbf{x}}_t) \\ p_{\text{short}}(z_t^k | \vec{\mathbf{x}}_t) \\ p_{\text{max}}(z_t^k | \vec{\mathbf{x}}_t) \\ p_{\text{rand}}(z_t^k | \vec{\mathbf{x}}_t) \end{bmatrix}. \quad (1.26)$$

Kapitel 2

Kartenerstellung

2.1 Occupancy-Grid-Mapping

In dem hiesigen Anwendungsfall sollen metrische Karten verwendet werden, um das Navigationsproblem lösen zu können. Ein passender Kartentyp sind die so genannten Occupancy-Grids, welche die Umgebung als 2- oder 3-dimensionales, diskretes Raster darstellen. Jeder Zelle der Karte wird eine Wahrscheinlichkeit zugeordnet, die wiedergibt, ob die Zelle belegt ist. Durch den stochastischen Charakter des Umgebungsmodells können Ungewissheiten bei der Kartographierung und anschließenden Navigation beachtet werden.

Mathematisch wird die Umgebung als diskrete Menge von binären Zufallsvariablen

$$M = \{m_i\} \quad (2.1)$$

beschrieben, die entweder den Zustand frei oder belegt annehmen können. Die Aufgabe des Kartographierungsalgorithmus besteht darin, eine Karte zu erstellen, wobei es sich um die a posteriori Wahrscheinlichkeit

$$p(M = \text{belegt} \mid \vec{z}_{1:t}, \vec{x}_{1:t})^1 \quad (2.2)$$

handelt. Für jede Zelle soll die Wahrscheinlichkeit, dass diese unter Beachtung aller bisheriger Sensorwerte $\vec{z}_{1:t}$ und aller Zustandswerte $\vec{x}_{1:t}$ belegt ist, ermittelt werden. Um dieses Problem zu lösen, wird als erster Ansatz ein Bayes-Filter für binäre Zufallsvariablen angeführt. Es werden die beiden folgenden Annahmen getroffen: Die Umgebung ist stationär, das heißt keine Objekte werden während der Kartenaufzeichnung verschoben. Somit kann der Algorithmus nicht genutzt werden, um dynamischen Hindernissen auszuweichen. Zweitens wird angenommen, dass die Wahrscheinlichkeiten der einzelnen Zellen unabhängig sind.

$$p(M \mid \vec{z}_{1:t}, \vec{x}_{1:t}) = \prod_i p(m_i \mid \vec{z}_{1:t}, \vec{x}_{1:t}) . \quad (2.3)$$

Dadurch können die a posteriori Wahrscheinlichkeiten der Zellen separat berechnet werden. Allerdings kann diese Annahmen unter realen Umständen kaum verteidigt werden, da Hindernisse für gewöhnlich größer als eine einzelne Kartenzelle sind.

¹Im Folgenden wird die Wahrscheinlichkeit für $M = \text{belegt}$ bzw. $m_i = \text{belegt}$ als $p(M)$ bzw. $p(m_i)$ geschrieben. Die Wahrscheinlichkeiten für freie Zellen werden mit $p(\neg m_i)$ denotiert.

Für die Berechnung der Karte wird das logarithmische Verhältnis

$$l(x) = \log \left[\frac{p(m_i)}{1 - p(m_i)} \right] = \log \left[\frac{p(m_i)}{p(\neg m_i)} \right], \quad (2.4)$$

die bei binären Zufallsvariablen rechentechnische Vorteile mit sich bringen [1, S. 94 f]. Bei der Kartenaufzeichnung soll das logarithmische Verhältnis $l(m_i)_t$ am Zeitpunkt t anhand des vergangenen Wertes $l(m_i)_{t-1}$, des Messvektors \vec{z}_t und des Zustandsvektors \vec{x}_t für alle i Zellen der Karte bestimmt werden. Die gesuchte Wahrscheinlichkeit ergibt sich aus

$$p(x \mid \cdot) = 1 - \frac{1}{1 + e^{l(x)_t}}. \quad (2.5)$$

Für die Herleitung des Bayes-Filter wird zunächst der Fall betrachtet, dass die Zelle m_i belegt ist. Nach Bayes-Theorem folgt für die a posteriori Wahrscheinlichkeit

$$\begin{aligned} p(m_i \mid \vec{z}_{1:t}) &= p(m_i \mid \vec{z}_t, \vec{z}_{1:t-1}) \\ &= \frac{p(\vec{z}_t \mid m_i, \vec{z}_{1:t-1}) \cdot p(m_i \mid \vec{z}_{1:t-1})}{p(\vec{z}_t \mid \vec{z}_{1:t-1})} \\ &= \frac{p(\vec{z}_t \mid m_i) \cdot p(m_i \mid \vec{z}_{1:t-1})}{p(\vec{z}_t \mid \vec{z}_{1:t-1})}. \end{aligned} \quad (2.6)$$

Wie Wahrscheinlichkeit $p(\vec{z}_t \mid m_i)$ heißt Messmodell, da sie angibt, wie wahrscheinlich ein Messwert \vec{z}_t aus einer gegebenen Umgebung m_i folgt. Aus Bayes-Theorem folgt wiederum

$$p(\vec{z}_t \mid m_i) = \frac{p(m_i \mid \vec{z}_t) \cdot p(\vec{z}_t)}{p(m_i)} \quad (2.7)$$

und die anschließende Substitution in 2.6 liefert

$$p(m_i \mid \vec{z}_{1:t}) = \frac{p(m_i \mid \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(m_i \mid \vec{z}_{1:t-1})}{p(m_i) \cdot p(\vec{z}_t \mid \vec{z}_{1:t-1})}. \quad (2.8)$$

Analog ergibt sich für das komplementäre Ereignis $\neg m_i$

$$p(\neg m_i \mid \vec{z}_{1:t}) = \frac{p(\neg m_i \mid \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(\neg m_i \mid \vec{z}_{1:t-1})}{p(\neg m_i) \cdot p(\vec{z}_t \mid \vec{z}_{1:t-1})}. \quad (2.9)$$

Im nächsten Schritt folgt der Quotient der beiden Verteilungen

$$\begin{aligned} \frac{p(m_i \mid \vec{z}_{1:t})}{p(\neg m_i \mid \vec{z}_{1:t})} &= \frac{p(m_i \mid \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(m_i \mid \vec{z}_{1:t-1}) \cdot p(\neg m_i) \cdot p(\vec{z}_t \mid \vec{z}_{1:t-1})}{p(\neg m_i \mid \vec{z}_t) \cdot p(\vec{z}_t) \cdot p(\neg m_i \mid \vec{z}_{1:t-1}) \cdot p(m_i) \cdot p(\vec{z}_t \mid \vec{z}_{1:t-1})} \\ &= \frac{p(m_i \mid \vec{z}_{1:t-1})}{p(\neg m_i \mid \vec{z}_{1:t-1})} \cdot \frac{p(m_i \mid \vec{z}_t)}{p(\neg m_i \mid \vec{z}_t)} \cdot \frac{p(\neg m_i)}{p(m_i)}, \end{aligned} \quad (2.10)$$

dessen Logarithmus das gesuchte Verhältnis liefert:

$$\begin{aligned} l(m_i)_t &\equiv \log \left[\frac{p(m_i \mid \vec{z}_{1:t})}{p(\neg m_i \mid \vec{z}_{1:t})} \right] \\ &= \underbrace{\log \left[\frac{p(m_i \mid \vec{z}_{1:t-1})}{p(\neg m_i \mid \vec{z}_{1:t-1})} \right]}_{=l(m_i)_{t-1}} - \underbrace{\log \left[\frac{p(\neg m_i)}{p(m_i)} \right]}_{=l(m_i)_{t=0} \equiv l_0} + \log \left[\frac{p(m_i \mid \vec{z}_t)}{p(\neg m_i \mid \vec{z}_t)} \right]. \end{aligned} \quad (2.11)$$

Somit setzt sich die gesuchte a posteriori Wahrscheinlichkeit aus drei Summanden zusammen. Bei dem Ersten handelt es sich um die Wahrscheinlichkeit $l(m_i)_{t-1}$ am vorherigen Abtastpunkt. Der Zweite gibt das Verhältnis der a priori Wahrscheinlichkeiten zum Zeitpunkt $t = 0$ wider und der letzte Teil ergibt sich aus dem logarithmischen Verhältnis von $p(m_i | \vec{z}_t)$, wobei es sich um ein inverses Messmodell handelt. Die Wahrscheinlichkeit $p(m_i | \vec{z}_t)$ wird von dem Entwickler vorgegeben und basiert auf der Charakteristik der Sensorik. Als Beispiel dient an dieser Stelle ein rudimentäres Modell für einen Laserscanner. Der Sensor gibt einen Vektor von Distanzmessungen zurück, die jeweils einen Messwinkel φ relativ zu dem Roboter zuzuordnen sind. Somit liegt ein Messbereich in Form eines Kegels mit dem Öffnungswinkel $\Delta\varphi$ vor, der durch die gemessenen Distanzen begrenzt wird. Im inversen Messmodell werden nun




Abbildung 2.1: Schematische Darstellung der Karten und des inversen Messmodells

drei Fälle unterschieden. Liegt eine Zelle außerhalb des Messkegels, kann keine Aussage über den Zustand der Zelle getroffen werden, weshalb der Wert l_0 zurückgegeben wird der in 2.11 eingesetzt zu

$$l(m_i)_t = l(m_i)_{t-1} + l_0 - l_0 = l(m_i)_{t-1} \quad (2.12)$$

führt. In dem Fall, dass die Zelle innerhalb des Messkegels liegt, wird geprüft auf welchem Messstrahl und in welcher Distanz die Zelle sich befindet. Ist der Abstand zwischen der Zelle und der gemessenen Distanz kleiner als ein Toleranzmaß α , wird angenommen, dass die Zelle belegt ist und ein entsprechender Wert l_{occupied} zurückgegeben. Liegt die Zelle mehr als α Einheiten vor der gemessenen Distanz, gilt sie als frei und das Modell liefert den Wert l_{free} .

Kapitel 3

ROS-Navigation-Stack

Bei dem ROS-Navigation-Stack handelt es sich um ein umfangreiches Software-Paket, das verschiedenste Funktionalitäten für das autonome Agieren eines Roboters bereitstellt. Von besonderem Interesse ist dabei das Paket *move_base*, welches bereits im Vorgängerprojekt für die Navigation des Roboters verwendet wurde. Funktional basiert das System auf einem zweischichtigen Planungskonzept: Zuerst berechnet ein globaler Planer anhand der vorgegebenen Karte einen optimalen Pfad zwischen Ausgangs- und Zielposition. Im Anschluss wird das Resultat an einen lokalen Planer übergeben, der die Stellgrößen des Roboters berechnet, um die geplante Trajektorie zu realisieren. Dabei werden neben dem optimalen Pfad ein lokaler Ausschnitt der Karte, Sensor- und Lokalisierungsdaten herangezogen, wodurch auch nicht vorhergesehene, dynamische Hindernisse bei der Planung beachtet werden können.

Im Gesamtkonzept spielen der lokale und globale Planer die entscheidenden Rollen, weshalb deren zu Grunde liegenden Algorithmen im Anschluss näher erläutert werden. Bei der Konfiguration ..

3.1 Funktionsprinzip des globalen Planers

Wie bereits erwähnt, wird die Navigationsaufgabe mithilfe zweier sukzessiver Planungsalgorithmen gelöst. Im ersten Schritt berechnet ein globaler Planer einen Weg zwischen der Ausgangs- und Zielposition, wofür die vorgegebene Karte herangezogen wird. Als Planungsalgorithmus werden im Navigation-Stack entweder Dijkstra- oder der A*-Algorithmus verwendet, die an dieser Stelle näher untersucht werden. Prinzipiell besteht die Aufgabe darin, einen Weg und Trajektorie zu ermitteln, die den Ausgangszustand des Roboters mit dem gewünschten Endzustand verbinden. Bei den gesuchten Pfaden handelt es sich um zeit- und ortskontinuierliche Kurven, woraus ein kontinuierlicher Raum von Lösungen resultiert, der nach einer optimalen durchsucht werden muss. Die Kontinuität des Suchraums stellt auf der Planungsseite eine immense Herausforderung dar, da eine unendliche Zahl von Möglichkeiten zur Verfügung stehen. **Viel zu schwammige Erklärung, kleinen Einschub über Probleme wie differenzialgleichungen und Gütefunktionale...** Um dieser Komplexität Herr zu werden wird der Suchraum diskretisiert und die Planungsaufgabe auf die Bestimmung einer Positionsfolge reduziert.

Allerdings wird die Diskretisierung des Raumes von mehr als einer reinen Vereinfachung des Suchproblems motiviert: Der globale Planer übernimmt lediglich den ersten Schritt bei der Berechnung der letztendlichen Trajektorie. Der lokale Planer berechnet anhand der globalen Sollkurve eine lokale Trajektorie, die in Form von Stellgrößen realisiert wird. Dabei werden neben der globalen Ortskurve auch aktuelle Sensor- und Lokalisierungsinformationen miteinbezogen, welche unter Umständen dazu führen können, dass der Roboter von der global geplanten Kurve abweicht. Insofern ergibt es wenig Sinn, bei der globalen Planung Ressourcen in eine unnötig genaue Trajektorie zu investieren; besonders dann, wenn noch nicht alle nötigen Informationen vorliegen. Für den Anfang genügt ein ungenauer, fehlerbehafteter Pfad, der die Anfangs- und Zielposition verbindet, wofür eine diskrete Darstellung des Suchraums vollkommen genügt. Des Weiteren stimmt die Forderung nach einer diskreten Darstellung des Suchraums mit den üblichen Darstellungsformen von metrischen Karten überein, denn diese repräsentieren die Umgebung in Form von diskreten Zellen.

Im Rahmen dieser Überlegung werden die vereinfachten Bedingungen zunächst in einer mathematischen Darstellung formuliert. Es wird angenommen, dass der Roboter in einer planen Umgebung manövriert, welche mittels einer zweidimensionalen Karte dargestellt werden kann. Hierfür wird eine metrische Karte verwendet, die den Raum in quadratische Zellen fixer Größe unterteilt. Die Positionen von Objekten innerhalb der Karten werden mithilfe des X- und Y-Indexes angegeben, wodurch die Positionsangaben von der Zellengröße entkoppelt werden. An dieser Stelle kann entweder ein deterministisches oder stochastisches Modell verwendet werden. Bei Erstem wird die Karte als Menge

$$M = \{m_{ij}\} \qquad m_{ij} \in \{0, 1\} \qquad (3.1)$$

dargestellt, wobei jede Zelle m_{ij} im belegten Fall den Wert 1 und ansonsten den Wert 0 annimmt. Bei den so genannten Occupancy-Grids handelt es sich eine stochastische Repräsentation: Für jede Zelle wird die Wahrscheinlichkeit angegeben, ob diese belegt ist.

Die Planungsaufgabe wird durch die Angabe einer Startposition \vec{x}_0 und einer Zielposition

\vec{x}_G definiert, wobei angenommen wird, dass sowohl \vec{x}_0 als auch \vec{x}_G freie Zellen sind. Zuletzt muss die Menge der möglichen Aktionen U spezifiziert werden. Hier wird eine weitere Vereinfachung vorgenommen. Die eigentlichen Stellgrößen des Roboters sind dessen Translations- und Rotationsgeschwindigkeit, welche sich allerdings auf zeit- und ortskontinuierliche Trajektorien führen. Da lediglich ortsdiskrete Pfade berechnet werden sollen, ergibt es Sinn, diskrete Positionsänderungen als Aktionen zu definieren. Beispielsweise kann die Verrückung um eine Zelle entlang der X- und Y-Richtung zugelassen werden. Da die Positionen in Form von Zellenindizes beschrieben werden, kann die Verrückung durch die Addition eines Vektors ausgedrückt werden, woraus die Aktionsmenge

$$U = \left\{ \vec{u}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \vec{u}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \vec{u}_3 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \vec{u}_4 = \begin{bmatrix} 0 \\ -1 \end{bmatrix} \right\} \quad (3.2)$$

resultiert. Von einem beliebigen Zustand \vec{x}_n ausgehend, kann mithilfe der Übergangsfunktion

$$\vec{x}_{n+1} = f(\vec{x}_n, \vec{u}) = \vec{x}_n + \vec{u} \quad (3.3)$$

der durch die Aktion \vec{u} erreichte Zustand \vec{x}_{n+1} ermittelt werden.

3.1.1 Forward-Search: Breiten Suche

Stehen die Ausgangsposition \vec{x}_0 , die Zielposition \vec{x}_G , die Menge der zulässigen Zustände X , welche durch die Karte M definiert wird, und eine Aktionsmenge U zur Verfügung, können erste rudimentäre Planungsalgorithmen entwickelt werden. Die Aufgabe besteht darin eine Sequenz von Aktionen oder Zuständen zu bestimmen, welche die Positionen \vec{x}_0 und \vec{x}_G miteinander verbinden. Dabei spielt es keine Rolle, ob Aktionen oder wegzusammenhängende Zustände berechnet werden, da beide Darstellungsformen des Pfades mithilfe ineinander überführt werden können. Als erster Ansatz für die Lösung des Planungsproblems kann die so genannte Forward-Search nach [2, S. 28] verfolgt werden:

Listing 3.1: Ablauf der Forward-Search in Pseudocode

```

1  Q.Insert( $\vec{x}_0$ ) and mark  $\vec{x}_0$  as visited
2  while Q not empty do
3     $\vec{x}_n = Q.GetFirst()$ 
4    if  $\vec{x}_n = \vec{x}_G$ 
5      return SUCCESS
6    forall  $\vec{u} \in U$ 
7       $\vec{x}_{n+1}$  not visited
8      Mark  $\vec{x}_{n+1}$  as visited
9      Q.Insert( $\vec{x}_{n+1}$ )
10 return FAILURE

```

Der Algorithmus basiert auf einer Datenstruktur Q , deren Funktionsprinzip die Charakteristik des Suchalgorithmus maßgeblich prägt. Bei der Initialisierung des Algorithmus wird die Anfangsposition \vec{x}_0 in die Datenstruktur eingefügt. Anschließend wird in einer Schleife die Struktur ausgelesen, wo zuerst geprüft wird, ob der aktuelle Zustand \vec{x}_n der gesuchten Zielposition \vec{x}_G gleicht und gegebenenfalls terminiert die Suche. Wurde das Ziel noch nicht erreicht, werden alle möglichen Aktionen \vec{u} auf den aktuellen Zustand \vec{x}_n angewandt, wodurch jeweils ein neuer Zustand \vec{x}_{n+1} erzeugt wird. Falls der neue Zustand \vec{x}_{n+1} noch nicht

geprüft wurde, wird er ebenfalls in die Datenstruktur Q eingefügt. Dadurch wird der Suchraum der möglichen Zustände systematisch durchsucht, wobei eine mehrmalige Prüfung des gleichen Zustandes durch eine Markierung verhindert wird. Wenn die Datenstruktur Q keine Elemente enthält, wurden alle möglichen Zustände geprüft; folglich kann das gewünschte Ziel nicht von der gegebenen Anfangsposition erreicht werden.

Das Funktionsprinzip der Datenstruktur Q gibt die Reihenfolge vor, in der die neu erschlossenen Zustände überprüft werden, wodurch die Suchstrategie festgelegt wird. Arbeitet Q nach dem FIFO-Prinzip, wird der Suchraum zuerst in der Breite und anschließend in der Tiefe erforscht. Als Beispiel dient eine beliebige Startposition \vec{x}_0 und die bereits genannte Aktionsmenge

$$U = \left\{ \vec{u}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \vec{u}_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \vec{u}_3 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, mVecu_4 = \begin{bmatrix} 0 \\ -1 \end{bmatrix} \right\}. \quad (3.2)$$

Die folgenden Zustände ergeben sich ebenfalls nach

$$\vec{x}_{n+1} = f(\vec{x}_n, \vec{u}) = \vec{x}_n + \vec{u}. \quad (3.3)$$

Folglich entspricht die Menge der am Iterationsschritt 1 möglichen Zustände dem Abbild

$$X_1 = f(\vec{x}_0, U) = \{\vec{x}_0 + \vec{u} \mid \vec{u} \in U\}. \quad (3.4)$$

Analog kann die Menge der möglichen Zustände an einem beliebigen Schritt $n + 1$ durch das Abbild

$$X_{n+1} = f(X_n, U) \quad (3.5)$$

bestimmt werden. Angenommen die Suche wird von einem beliebigen Startzustand \vec{x}_0 begonnen, so wird im ersten Schleifendurchlauf das Abbild X_1 bestimmt und in die Datenstruktur eingefügt. Arbeite diese nun nach dem FIFO-Prinzip werden in den folgenden Durchläufen die Elemente der Menge X_1 bearbeitet, wodurch die Menge X_2 berechnet und in die Datenstruktur eingefügt werden. Da die Elemente von X_2 aber nach denen von X_1 in die Schlange eingefügt werden, wird sichergestellt, dass zuerst alle Elemente von X_1 geprüft werden, bevor die Bearbeitung von X_2 stattfindet. Aus diesem Grund wird diese Suchstrategie als Breadth-First bezeichnet, da zuerst alle Möglichkeiten eines Iterationsschrittes geprüft werden, bevor die nachfolgende Iteration betrachtet wird. Stell man den Suchraum als Baum dar, wird die Bedeutung der Begriffe Tiefe und Breite deutlich.

Mit der Breadth-First-Search liegt ein systematischer Ansatz vor, der einen Pfad zum Ziel findet, falls ein solcher existiert. Außerdem ist recht leicht ersichtlich, dass der Algorithmus immer auf einen möglichst kurzen Lösungspfad führt. Um das Konzept zu illustrieren, wird folgendes Beispiel betrachtet: Ein Roboter befindet sich in einem Korridor an einer bekannten Position \vec{x}_0 . Die Umgebung wurde mittels einer deterministischen Karte

$$M = \{m_{ij}\} \quad \forall m_{ij} \in \{0, 1\} \quad (3.6)$$

dokumentiert, wobei die Zellen eine Kantenlänge von 25cm besitzen. Die Zielposition \vec{x}_G liegt am Ende des Korridors. Das Ergebnis der Breitensuche zeigt die folgende Abbildung, an der

ersichtlich wird, dass es sich um

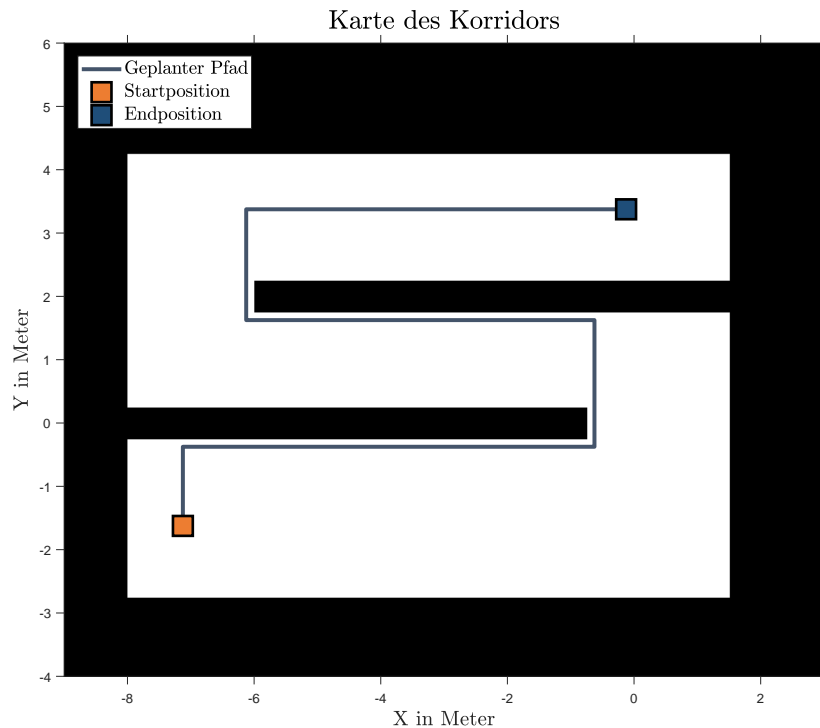


Abbildung 3.1: Ergebnis der Breitensuche

3.1.2 Forward-Search: Tiefensuche

Die komplementäre Suchstrategie wird als Depth-First-Search bezeichnet, bei der zuerst die Tiefe des Suchbaums erforscht wird, bevor parallele Zweige überprüft werden. Die Umsetzung der Depth-First-Search erfolgt indem die Datenstruktur Q als LIFO-Speicher implementiert wird. Dadurch kann im Vergleich zu der Breadth-First-Search die Suchzeit unter Umständen drastisch reduziert werden, allerdings resultieren für gewöhnlich längere Pfade. Wenn die Anzahl der Iterationsschritte oder die Menge der zulässigen Zustände begrenzt sind, wird auch die Depth-First-Search zu einem systematischen Suchansatz. Das heißt der Algorithmus stößt garantiert auf ein Ergebnis, falls ein solches existiert. Durch das LIFO-Prinzip der Datenstruktur wird das Ergebnis der zuletzt ausgeführten Aktion unmittelbar weiterverfolgt. Dadurch bekommt die Reihenfolge, in der die möglichen Aktionen \vec{u} appliziert werden, eine zentrale Bedeutung, da dadurch die Suchrichtung vorgegeben wird. Die folgenden Abbildungen zeigen die Auswirkungen einer veränderten Aktionsreihenfolge anhand des Korridorbeispiels.

Prinzipiell kann die Suche - unabhängig von der gewählten Strategie - auch von der Zielposition ausgehend beginnen. In diesem Fall wird von einer so genannten Backwards-Search gesprochen. Werden Forward- und Backward-Search simultan verfolgt, resultiert die so genannten Bidirectional-Search. Diese Adaptionen können unter Umständen verkürzte Suchzeiten liefern, werden an dieser Stelle aber nicht weiterverfolgt, da dieser Aspekt bei dem hiesigen Anwendungsfall nicht zum Tragen kommt.

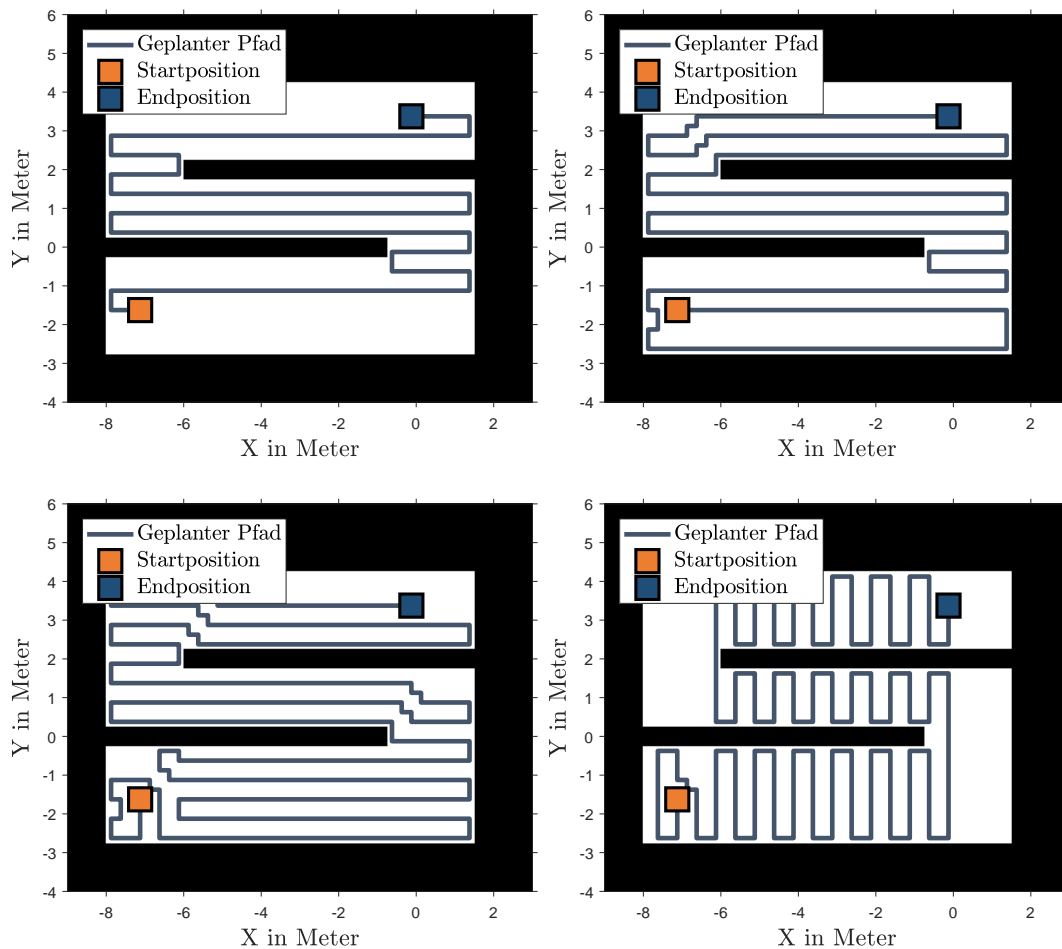


Abbildung 3.2: Ergebnisse der Tiefensuche bei unterschiedlichen Reihenfolge der Aktionen

3.1.3 Optimale Suche und Planung

In den bisherigen Suchalgorithmen bestand die Aufgabe lediglich darin, einen Pfad zwischen Ausgangs- und Zielposition zu finden. Dies hatte unter anderem zur Folge, dass starke Unterschiede zwischen den Lösungen der verschiedenen Ansätze resultierten. Besonders bei der Depth-First-Search kamen zum Teil äußerst umständliche Pfade zu Stande. Aus diesem Grund soll im nächsten Schritt eine Bewertung der Lösungsmöglichkeiten eingeführt werden, die genutzt wird, um einen optimalen Pfad im Sinne dieses Gütekriteriums zu ermitteln. Bei der globalen Pfadplanung sollen prinzipiell zwei Aspekte beachtet werden: Einerseits soll der resultierende Pfad möglichst kurz sein, andererseits soll ein gewisser Abstand zu belegten Zellen der Karte gehalten werden bzw. die belegten Zellen sollen von dem Pfad nicht durchkreuzt werden. Um diese Vorgaben in einem Gütekriterium auszudrücken, wird die Karte in eine sogenannte Kostenkarte transformiert. Diese ordnet jeder Zelle einen Aufwand zu, wodurch es möglich wird verschiedenen Pfade zu bewerten und miteinander zu vergleichen. Die Kosten eines Pfades ergeben sich aus der Summe der enthaltenen Zellen. Ein Beispiel für eine mögliche Bewertung der Zellen ordnet jeder freien Zelle den Aufwand 1 und jeder belegten Zelle den Wert ∞ zu. Durch letzteren wird sichergestellt, dass belegte Zellen vermieden werden. Die Gewichtung von freien Zellen führt dazu, dass kürzere Pfade mit geringeren Kosten verbunden sind. Eine Möglichkeit, um einen im Kontext der Kostenkarte optimalen Pfad zu berechnen, stellt Dijkstra's Algorithmus dar. Dieser gleicht im Grundprinzip den bis-

her betrachteten Vorgehensweise, mit dem Unterschied, dass die Datenstruktur Q so sortiert werden, dass das Element mit den aktuell geringstem Kostenaufwand am Anfang der Liste steht. Zusätzlich muss in dem Fall, dass ein Zustand geprüft wird, der bereits besucht worden ist, verglichen werden, welcher der beiden Pfade den geringeren Aufwand benötigt.

Listing 3.2: Dijkstra's Algorithmus in Pseudocode

```

1  Q.Insert( $\vec{x}_0$ ) and mark  $\vec{x}_0$  as visited
2  while  $Q$  not empty do
3     $\vec{x}_n = Q.$ GetFirst()
4    if  $\vec{x}_n = \vec{x}_G$ 
5      return SUCCESS
6    forall  $\vec{u} \in U$ 
7      if  $\vec{x}_{n+1}$  not visited
8        Mark  $\vec{x}_{n+1}$  as visited
9         $Q.$ Insert( $\vec{x}_{n+1}$ )
10     else
11       resolve duplicate
12 return FAILURE

```

Die folgende Abbildung zeigt die Ergebnisse der Suche bei dem bekannten Anwendungsbeispiel.




Abbildung 3.3: Ergebnis mit Dijkstra's Algorithmus

A*

Indem bei Dijkstra's Algorithmus die Liste Q nach aufsteigenden Kosten sortiert wird, kann gesichert werden, dass die Suche zu einem optimalen Ergebnis führt. Allerdings bringt dieses Vorgehen einen zum Teil unnötigen Suchaufwand mit sich, was recht leicht illustriert werden kann: Um möglichst kurze Pfade zu erhalten, wurde jeder weitere Schritt mit einem fixen Aufwand bewertet. Dies hat zur Folge, dass die kürzesten Pläne an den Anfang der Liste rücken, inklusive der Pfade, die entweder zu kurz sind, um das Ziel überhaupt erreichen zu können, als auch solche die sich in eine falsche Richtung bewegen. Insofern erzwingt die sortierte Datenstruktur eine Breitensuche, da kurze Pfade fälschlicherweise - zumindest teilweise fälschlicherweise - mit weniger Aufwand verbunden sind.

Ein Ansatz, um dieser Problematik vorzubeugen, stellt der A^* Algorithmus dar, der nach dem identischen Grundprinzip wie Dijkstra's Algorithmus arbeitet. Lediglich das Gewichtungskonzept der Pläne unterscheiden die beiden Vorgehensweisen. Für jede Position \vec{x}_n existiert ein optimaler Pfad, welcher \vec{x}_n mit der Zielposition \vec{x}_G verbindet. Die Kosten des optimalen Pfades werden von der Funktion $G^*(\vec{x}_n)$ beschrieben. Die Idee des A^* Algorithmus besteht darin, neben den Kosten des Pfades von \vec{x}_0 zu \vec{x}_n auch die verbleibenden Kosten nach \vec{x}_G zu beachten. Dadurch werden kürzere Pfade nicht mehr aus Prinzip bevorzugt, sondern lediglich dann, wenn ihre erwarteten Kosten bis zum Ziel ebenfalls gering sind. Da die optimalen Kosten $G^*(\vec{x}_n)$ nicht bekannt sind müssen sie mithilfe approximiert werden, wofür eine heuristische Schätzung $G(\vec{x}_n)$ eingeführt wird. An die Heuristik ist die Bindung geknüpft, dass die geschätzten Kosten $G(\vec{x}_n)$ stets kleiner oder gleich der optimalen Kosten $G^*(\vec{x}_n)$ sind:

$$G(\vec{x}_n) \leq G^*(\vec{x}_n) \quad \forall \vec{x}_n \in X. \quad (3.7)$$

Als Beispiel wird wieder die Navigation durch den Korridor betrachtet. Hier wurde jede Verrückung mit dem Aufwand 1 gewichtet, woraus folgt, dass die Kosten zwischen \vec{x}_n und \vec{x}_G mindestens gleich der absoluten Differenzen zwischen den X- und Y-Koordinaten der beiden Positionen sein muss. Im Falle, dass ein Hindernis den direkten Weg zwischen \vec{x}_n und \vec{x}_G versperrt nehmen die optimalen Kosten $G^*(\vec{x}_n)$ weiter zu, weshalb

$$G(\vec{x}_n) = |x_n - x_G| + |y_n - y_G| \leq G^*(\vec{x}_n) \quad \forall \vec{x}_n \in X \quad (3.8)$$

stets gilt. Somit stellt $G(\vec{x}_n)$ eine legitime Approximation der optimalen Kosten $G^*(\vec{x}_G)$ dar. Wird diese Forderung an die Kostenschätzung eingehalten, kann bewiesen werden, dass der A^* Algorithmus stets eine optimale Lösung findet, insofern diese existiert [2, S. 32][3, 4]. Bei der - recht konservativen - Schätzung $G(\vec{x}_n) = 0$ geht das A^* Verfahren in Dijkstra's Algorithmus über.




Abbildung 3.4: Ergebnis mit dem A^* Algorithmus

3.2 Lokaler Planer: Dynamic Window Approach

Nachdem die Berechnung eines Pfades zwischen Ausgangs- und Zielposition mittels A^* gelöst wurde, muss als nächstes eine Folge von Steuerkommandos ermittelt werden, um den geplanten Pfad abzufahren. Den Ausgangspunkt stellt die Dynamik des Roboters dar: Die Position des Roboters wird in dem Zustandsvektor

$$\vec{x}(t) = \begin{pmatrix} x \\ y \\ \theta \end{pmatrix} \quad (3.9)$$

erfasst, wobei die ersten beiden Größen die Position und der Winkel θ die Blickrichtung des Roboters beschreiben. Nach wie vor gilt die Annahme, dass der Roboter in einer planen Umgebung manövriert. Die Positionsänderung wird mithilfe einer Translationsgeschwindigkeit v und einer Rotationsgeschwindigkeit ω erfasst, die wiederum in dem Vektor

$$\vec{u} = \begin{pmatrix} v \\ \omega \end{pmatrix} \quad (3.10)$$

zusammengefasst werden. Bei den Turtlebots werden die Motoren drehzahl geregelt, weshalb der Geschwindigkeitsvektor \vec{u} die Stellgröße zur Ansteuerung des Roboters darstellt. wird die Annahme getroffen, dass die an einem Zeitpunkt $n \cdot T_a$ eingestellte Geschwindigkeit für die folgende Abtastperiode konstant ist, kann die Positionsänderung in X- und Y-Richtung mittels der folgenden Gleichungen berechnet werden:

$$x_{n+1} = x_n + \Delta x(n) \quad (3.11)$$

$$y_{n+1} = y_n + \Delta y(n) \quad (3.12)$$

$$\Delta x(n) = \begin{cases} \frac{v_n}{\omega_n} \cdot (\sin[\theta_n] - \sin[\theta_n + \omega_n \cdot T_a]) & \forall \omega_n \neq 0 \\ v_n \cdot \cos[\theta_n] \cdot T_a & \forall \omega_n = 0 \end{cases} \quad (3.13)$$

$$\Delta y(n) = \begin{cases} -\frac{v_n}{\omega_n} \cdot (\cos[\theta_n] - \cos[\theta_n + \omega_n \cdot T_a]) & \forall \omega_n \neq 0 \\ v_n \cdot \sin[\theta_n] \cdot T_a & \forall \omega_n = 0 \end{cases} \quad (3.14)$$

Aus den zeitweise konstanten Geschwindigkeiten resultiert eine Kreisbahn mit dem Radius v_n/ω_n im Falle, dass $\omega_n \neq 0$ gilt. Im Extremfall mit $\omega_n = 0$ bewegt der Roboter sich rein translativ entlang einer Geraden. Somit wird der Raum der möglichen Trajektorien auf Kreisbahnen reduziert, wodurch die Komplexität des folgenden Suchproblems drastisch reduziert wird.

Unter den obigen Annahmen soll nun ein Geschwindigkeitsvektor \vec{u} gewählt werden, um den Roboter in Richtung eines gegebenen Zielpunktes zu fahren, der in der näheren Umgebung liegt. Im ersten Schritt wird der Versuch unternommen, den Suchraum der möglichen Geschwindigkeiten durch Nebenbedingungen weiter einzugrenzen. Sowohl für die Translations- als auch die Rotationsgeschwindigkeit bestehen Maxima, die nicht überschritten werden dürfen, woraus die Menge

$$V_s = \{(v, \omega) \mid v < v_{\max} \wedge \omega < \omega_{\max}\} \quad (3.15)$$

resultiert. Neben den Geschwindigkeiten sind auch die Beschleunigungen beschränkt, weshalb die Menge der erreichbaren Geschwindigkeiten durch die aktuellen Geschwindigkeiten v_a und ω_a , und die maximalen Beschleunigungen eingeschränkt werden.

$$V_a = \{(v, \omega) \mid v \in [v_a - \dot{v}_{\max} \cdot T_a, v_a + \dot{v}_{\max} \cdot T_a] \wedge \omega \in [\omega_a - \dot{\omega}_{\max} \cdot T_a, \omega_a + \dot{\omega}_{\max} \cdot T_a]\} . \quad (3.16)$$

Als dritte Begrenzung des Suchraums werden Hindernisse in der Umgebung herangezogen. Jedem Geschwindigkeitspaar (v, ω) kann eine Kreisbahn zugeordnet werden, wobei die Funktion $\text{dist}(v, \omega)$ die Distanz des nächsten Hindernisses am Ende der Abtastperiode auf der zugehörigen Kreisbahn wiedergibt. Wenn nun eine maximale Verzögerung von \dot{v}_{\max} und $\dot{\omega}_{\max}$ erreicht werden kann, folgt für die maximal erlaubte Geschwindigkeit, um vor dem Hindernis bremsen zu können:

$$V_d = \left\{ (v, \omega) \mid v \leq \sqrt{2 \cdot \text{dist}(v, \omega) \cdot \dot{v}_{\max}} \wedge \omega \leq \sqrt{2 \cdot \text{dist}(v, \omega) \cdot \dot{\omega}_{\max}} \right\} . \quad (3.17)$$

Der Raum der zulässigen Geschwindigkeiten ergibt sich aus dem Schnitt der drei Mengen

$$V = V_s \cap V_a \cap V_d . \quad (3.18)$$

Nun gilt es eine Geschwindigkeit aus dem Suchraum V auszuwählen, wofür wiederum ein Gütekriterium definiert wird, dessen Optimum erzielt werden muss. Bei der Auswahl der Zielfunktion werden drei Aspekte berücksichtigt: Der Roboter soll sich möglichst weit in Richtung des Zielpunktes bewegen, die Blickrichtung des Roboters soll am Ende der folgenden Abtastperiode auf den Zielpunkt gerichtet sein, und die Distanz zwischen dem Roboter und Hindernissen soll möglichst groß gehalten werden. Diese drei Teilziele werden jeweils durch eine separate Funktion beschrieben, deren Summe bei der Suche maximiert werden soll. Die Richtungsabweichung wird durch die Funktion

$$\text{heading}(v, \omega) = \pi - \varphi \quad \varphi = \angle \quad (3.19)$$

erfasst, wobei φ den Winkel zwischen Blickrichtung und Zielpunkt beschreibt. Die Gewichtung der Geschwindigkeit erfolgt mittels einer simplen Gerade der Form

$$\text{velocity}(v, \omega) = a \cdot v . \quad (3.20)$$

Um den Abstand von Hindernissen zu bewerten, wird wieder die bekannte Funktion $\text{dist}(v, \omega)$ verwendet, wobei zu beachten ist, dass im Falle einer Kurve ohne Hindernisse eine recht große Konstante zurückgeliefert wird. Zusammengeführt ergeben die einzelnen Teile die Zielfunktion

$$G(v, \omega) = \alpha \cdot \text{heading}(v, \omega) + \beta \cdot \text{velocity}(v, \omega) + \gamma \cdot \text{dist}(v, \omega) , \quad (3.21)$$

wobei die Faktoren α , β und γ zur Normierung der Teilzielfunktionen verwendet werden. Dadurch wird sichergestellt, dass keine der drei Funktionen das Ergebnis der Optimierung überproportional beeinflusst.

3.2.1 Anwendungsbeispiel

Um die Funktionsprinzipien des lokalen Planers besser nachvollziehen zu können, wird an dieser Stelle schrittweise eine Implementierung erarbeitet, die anschließend in der Simulation verifiziert wird. Im ersten Schritt werden die Bedingungen für die zulässigen Geschwindigkeiten konstruiert, wofür Angaben für die maximalen Geschwindigkeiten benötigt werden. Diese werden im Datenblatt des TurtleBot [5] mit

$$v_{\max} = 0.65 \quad \omega_{\max} = \pi \quad (3.22)$$

spezifiziert. Über die maximalen Verzögerung der Aktoren sagt das Datenblatt nichts aus, weshalb an dieser Stelle die Annahmen von

$$\dot{v}_{\max} = 0.65 \quad \dot{\omega}_{\max} = \pi \quad (3.23)$$

getroffen wird. Für die spätere Anwendung können die maximalen Beschleunigungen experimentell ermittelt werden und auch in der Simulation adaptiert werden. Die aktuellen Geschwindigkeiten v_a und ω_a können den Odometriedaten entnommen werden, welche über die ROS-Topic `\odom` veröffentlicht werden.

Als letzte Einschränkung ist der Abstand zwischen nächstem Hindernis und dem Turtlebot zu beachten, der mithilfe der Funktion $\text{dist}(v, \omega)$ berechnet wird. Die Implementierung der Distanzfunktion macht sich wieder den Umstand zu nutzen, dass die Menge der möglichen Trajektorien begrenzt ist: Der Roboter bewegt sich auf einer Kreisbahn mit dem Radius $r = \frac{v}{\omega}$, deren Mittelpunkt M simultan als Ursprung des Koordinatensystems verwendet wird.




Abbildung 3.5: Darstellung der Trajektorie und Hindernissen

Somit folgt für die Position des TurtleBot

$$\vec{\mathbf{p}}_R = \begin{cases} -\begin{pmatrix} r \\ 0 \end{pmatrix} & \forall \omega < 0 \\ \begin{pmatrix} r \\ 0 \end{pmatrix} & \forall \omega > 0 \end{cases}, \quad (3.24)$$

wobei der Fall $\omega = 0$ separat betrachtet werden muss. Da es sich bei dem Roboter um keinen Punkt sondern eine Kreisscheibe mit dem Radius r_R handelt, wird ein Schlauch mit Innenradius $r_I = r - r_R$ und Außenradius $r_A = r + r_R$ überfahren. Diese Fläche kann in Polarkoordinaten als die Punktmenge

$$K_R = \{(\phi, s) \mid s \in [r_I, r_A] \wedge \phi \in [0, 2 \cdot \pi]\} \quad (3.25)$$

dargestellt werden. Der Laserscanner liefert einen Messvektor \vec{z} , dessen Element jeweils ein Paar (φ_n, r_n) sind, das sowohl den Winkel zwischen Messstrahl und Blickrichtung als auch die darauf gemessene Entfernung r_n beschreibt. Folglich stellt das Paar die Position eines Messpunktes relativ zu dem TurtleBot dar, wobei die Darstellung in Form von Polarkoordinaten vorliegt. Liegt der Messpunkt zwischen den Kreisbahnen $r + r_T$ und $r - r_T$ blockiert er die Bahn des Roboters. Des Weiteren muss beachtet werden, dass eine finite Anzahlen von Messstrahlen vorliegt, weshalb jeder Messpunkt einen Messkegel mit Öffnungswinkel $2 \cdot \Delta\varphi$ repräsentiert. Insofern ergibt es Sinn zu prüfen, ob der Kreis mit Mittelpunkt (φ_n, r_n) und Radius $\Delta\varphi \cdot r_n$ die Bahn des Roboters schneidet. Als zusätzliche Absicherung kann der Kreis um den Messpunkt um einen Sicherheitsabstand r_s erweitert werden. Eine mathematische Formulierung resultiert, indem die Position des Messpunktes \vec{p}_n zunächst in dem Koordinatensystem dargestellt wird:

$$\vec{p}_n = \vec{p}_R + \begin{pmatrix} \sin[\varphi_n] \cdot r_n \\ \cos[\varphi_n] \cdot r_n \end{pmatrix}. \quad (3.26)$$

Die im Kreis enthaltene Menge ergibt sich aus allen Punkten, deren Abstand zu dem Messpunkt kleiner als der Radius ist:

$$K_M = \{\vec{p} \mid \|\vec{p} - \vec{p}_n\| \leq \Delta\varphi \cdot r_n + r_s\}. \quad (3.27)$$

Somit kann formal geprüft werden, ob das in einer Messung (φ_n, r_n) identifizierte Hindernis auf einer durch das Geschwindigkeitspaar (v, ω) definierten Kreisbahn liegt. Ergibt der Schnitt der Mengen

$$K_R \cap K_M \quad (3.28)$$

die leere Menge \emptyset , so wird die Trajektorie nicht von dem Hindernis blockiert. Allerdings stellt die Berechnung der Schnittmenge kein elegantes Verfahren dar, um die Position des Hindernisses zu prüfen. An dieser Stelle bietet es sich an, den Abstand d eines Messpunktes \vec{p}_n zu dem Ursprung M zu berechnen;

$$d = \|\vec{p}_n\|. \quad (3.29)$$

Alle Punkte des Messkreises K_M liegen zwischen dem maximalen Abstand

$$d_{\max} = d + \Delta\varphi \cdot r_n + r_s \quad (3.30)$$

und dem minimalen Abstand

$$d_{\min} = d - \Delta\varphi \cdot r_n - r_s, \quad (3.31)$$

wodurch sich die Prüfung auf eine simple Fallunterscheidung reduziert. Liegt einer der Ab-

stände d_{\max} und d_{\min} zwischen den Radien r_A und r_I , so blockiert das Hindernis die Kreisbahn. Das selbe Resultat ergibt sich in dem Fall, dass sowohl $d_{\max} > r_A$ als auch $d_{\min} < r_I$ gilt. Liegt ein Hindernis auf der Bahnkurve, so entspricht dessen Winkelposition γ der Polarkoordinate des Messpunktes

$$\gamma = \angle \vec{p}_n, \quad (3.32)$$

woraus für die auf der Kreisbahn zurückzulegende Distanz

$$\text{dist}(v, \omega) = \gamma \cdot r \quad (3.33)$$

folgt. In dem Falle einer nicht blockierten Trajektorie, gibt die Funktion die maximale Distanz zurück, die in einem Intervall passiert werden kann.

$$\text{dist}(v, \omega) = \begin{cases} v_{\max} \cdot T_a & \forall n : K_R \cap K_M = \emptyset \\ \gamma \cdot r & \exists n : K_R \cap K_M \neq \emptyset \end{cases} \quad (3.34)$$

Somit liegen nun alle Mittel bereit, um den begrenzten Suchraum

$$V = V_s \cap V_a \cap V_d \quad (3.35)$$

zu konstruieren. Im nächsten Schritt muss die Zielfunktion

$$G(v, \omega) = \alpha \cdot \text{heading}(v, \omega) + \beta \cdot \text{velocity}(v, \omega) + \gamma \cdot \text{heading}(v, \omega) \quad (3.36)$$

maximiert werden, wofür zunächst die Funktionen $\text{heading}(v, \omega)$ und $\text{velocity}(v, \omega)$ implementiert werden müssen. Letztere gibt lediglich den Geschwindigkeitswert zurück:

$$\text{velocity}(v, \omega) = v. \quad (3.37)$$

Die Funktion $\text{heading}(v, \omega)$ gestaltet sich als etwas schwieriger, da hier der Winkel zwischen dem Zielpunkt und der Blickrichtung des Roboters berechnet werden soll. Hier stellt sich die Frage, welcher Punkt als Ziel anvisiert werden soll. Immerhin wurde bei der globalen Planung eine Folge von Positionen berechnet, die den Pfad zum letztendlichen Ziel bilden. Ein Ansatz besteht darin, den geplanten Pfad schrittweise abzuarbeiten, d.h. jeweils der erste Punkte wird angefahren. Wurde das lokal aktuelle Ziel erreicht wird der nächste Punkt des Pfades als lokales Ziel vorgegeben. Bei dieser Variante ergibt sich das Problem, dass eventuell mehrere Punkte des globalen Pfades in einem Abtastintervall erreicht werden können. Wird nun lediglich der erste anvisiert, bewegt sich der Roboter unnötig langsam. Aus diesem Grund kann ein zweiter Ansatz verfolgt werden, bei dem der Punkt des Pfades als Ziel verwendet wird, der einerseits in dem Abtastintervall erreicht werden kann, andererseits aber möglichst weit von der aktuellen Position entfernt ist. In den folgenden Simulationen werden beide Vorgehensweisen implementiert und miteinander verglichen.

Steht ein Zielpunkt fest und ist die Position des Roboters bekannt - was in der ersten Simulationsreihe angenommen wird -, so kann der Winkel ϕ zwischen Blickrichtung und

Zielposition mithilfe simpler Trigonometrie berechnet werden. Es folgt

$$\text{heading}(v, \omega) = \pi - \phi. \quad (3.38)$$

Zuletzt müssen die Gewichtungsfaktoren α , β und γ gewählt werden. Sollen alle drei Funktionen das Optimierungsergebnis gleichermaßen beeinflussen bieten sich die Gewichtungen

$$\alpha = \frac{1}{\pi}; \quad \beta = \frac{1}{v_{\max}}; \quad \gamma = \frac{1}{v_{\max} \cdot T_a} \quad (3.39)$$

an. Alternativ können die Ziel unterschiedlich stark in die Bewertung einfließen indem die Gewichte ungleich verteilt werden. Für die Lösung des Suchproblems bietet es sich an, den Suchraum zu diskretisieren, das heißt es werden Geschwindigkeitsinkremente Δv und $\Delta \omega$ gewählt, woraus die Menge $G(V)$ berechnet wird. Das Optimum

$$\operatorname{argmax} G(V) \quad (3.40)$$

kann durch einen simplen brute-force Ansatz bestimmt werden. Bei der Wahl der Abtastintervalle Δv und $\Delta \omega$ ist ein Kompromiss zwischen Rechenaufwand und Qualität des Ergebnisses zu treffen. Dieser Einfluss wird in der anschließend Simulation weiter untersucht.

Kapitel 4

Stochastische Filter

In diesem Kapitel werden für die Robotik typische Filtermethoden vorgestellt und diskutiert. Dabei soll einerseits ein Einblick in die Prinzipien der stochastischen Modellierung geschaffen werden, andererseits sollen die später bei der Lokalisierung verwendeten Filter erarbeitet werden.

4.1 Kontinuierliches Bayes Filter

In der Robotik werden stochastische Filter genutzt, um anhand von gegebenen Information wie Mess- und Stellgrößen eine Schätzung über unbekannte Zustände des Systems zu treffen. Die Grundlage für derartige Methoden stellt das Bayes-Filter für kontinuierlich verteilte Zustände dar. Als Beispiel für die Herleitung und Illustration des Filters wird die Lokalisierungsaufgabe herangezogen, bei welcher die aktuelle Position \vec{x}_t des Roboters ermittelt werden soll. Die Schätzung stützt sich dabei auf die bisher gesammelten Messwerte $\vec{z}_{1:t}$ und Stellgrößen $\vec{u}_{1:t}$. Insofern kann die Lokalisierungsaufgabe als die Bestimmung der bedingten Wahrscheinlichkeit

$$p(\vec{x}_t \mid \vec{z}_{1:t}, \vec{u}_{1:t}) \quad (4.1)$$

reformuliert werden, die im Folgenden auch mittels der Definition

$$\text{bel}(\vec{x}_t) \equiv p(\vec{x}_t \mid \vec{z}_{1:t}, \vec{u}_{1:t}) \quad (4.2)$$

abgekürzt wird. Im Falle, dass der aktuelle Messwert \vec{z}_t bei der Verteilung nicht beachtet wird, gilt

$$\overline{\text{bel}}(\vec{x}_t) \equiv p(\vec{x}_t \mid \vec{z}_{1:t-1}, \vec{u}_{1:t}) . \quad (4.3)$$

Für die Bestimmung der Filtergleichungen wird auf Bayes Theorem zurückgegriffen:

$$\begin{aligned} \text{bel}(\vec{x}_t) &= p(\vec{x}_t \mid \vec{z}_t, \vec{z}_{1:t-1}, \vec{u}_{1:t}) = \frac{p(\vec{z}_t \mid \vec{x}_t, \vec{z}_{1:t-1}, \vec{u}_{1:t}) \cdot p(\vec{x}_t \mid \vec{z}_{1:t-1}, \vec{u}_{1:t})}{p(\vec{z}_t \mid \vec{z}_{1:t-1}, \vec{u}_{1:t})} \\ &= \mu \cdot p(\vec{z}_t \mid \vec{x}_t, \vec{z}_{1:t-1}, \vec{u}_{1:t}) \cdot p(\vec{x}_t \mid \vec{z}_{1:t-1}, \vec{u}_{1:t}) . \end{aligned} \quad (4.4)$$

Der Einfluss der bedingte Wahrscheinlichkeit $p(\vec{z}_t \mid \vec{z}_{1:t-1}, \vec{u}_{1:t})$ wird dabei durch den Faktor μ ersetzt, der für die Normalisierung reserviert wird, um sicherzustellen, dass es sich bei $\overline{\text{bel}}(\vec{x}_t)$ um eine legitime Wahrscheinlichkeitsverteilung handelt. Eine weitere Vereinfachung basiert

auf der Annahme, dass \vec{x}_t einen so genannten vollständigen Zustand darstellt, das heißt \vec{x}_t beinhaltet bereits alle vergangen Information. Aus diesem Grund verändern zusätzliche Informationen aus vergangen Mess- und Stellgrößen eine mit \vec{x}_t bedingte Wahrscheinlichkeit nicht, woraus

$$p(\vec{z}_t \mid \vec{x}_t, \vec{z}_{1:t-1}, \vec{u}_{1:t}) = p(\vec{z}_t \mid \vec{x}_t) \quad (4.5)$$

resultiert. Wird dieses Ergebnis in die ursprüngliche Gleichung eingesetzt, ergibt sich

$$\begin{aligned} \text{bel}(\vec{x}_t) &= \mu \cdot p(\vec{z}_t \mid \vec{x}_t) \cdot p(\vec{x}_t \mid \vec{z}_{1:t-1}, \vec{u}_{1:t}) \\ &= \mu \cdot p(\vec{z}_t \mid \vec{x}_t) \cdot \overline{\text{bel}}(\vec{x}_t) . \end{aligned} \quad (4.6)$$

Mithilfe von weiteren Annahmen kann auch die Wahrscheinlichkeit $\overline{\text{bel}}(\vec{x}_t)$ ermittelt werden, wofür diese zunächst erweitert wird.

$$\begin{aligned} \overline{\text{bel}}(\vec{x}_t) &= p(\vec{x}_t \mid \vec{z}_{1:t}, \vec{u}_{1:t}) \\ &= \int p(\vec{x}_t \mid \vec{x}_{t-1}, \vec{z}_{1:t-1}, \vec{u}_{1:t}) \cdot p(\vec{x}_{t-1} \mid \vec{z}_{1:t-1}, \vec{u}_{1:t}) d\vec{x}_{t-1} . \end{aligned} \quad (4.7)$$

Falls \vec{x}_{t-1} ebenfalls ein vollständiger Zustand ist kann eine Vereinfachung der Form

$$p(\vec{x}_t \mid \vec{x}_{t-1}, \vec{z}_{1:t-1}, \vec{u}_{1:t}) = p(\vec{x}_t \mid \vec{x}_{t-1}, \vec{u}_t) \quad (4.8)$$

durchgeführt werden. Wenn zusätzlich angenommen werden kann, dass \vec{u}_t zufällig gewählt wird und somit kein Zusammenhang zwischen \vec{x}_{t-1} und \vec{u}_t besteht, folgt

$$p(\vec{x}_{t-1} \mid \vec{z}_{1:t-1}, \vec{u}_{1:t}) = p(\vec{x}_{t-1} \mid \vec{z}_{1:t-1}, \vec{u}_{1:t-1}) = \text{bel}(\vec{x}_{t-1}) . \quad (4.9)$$

Die Substitution der beiden Ergebnisse (4.8) und (4.9) in Gleichung (4.7) liefert

$$\overline{\text{bel}}(\vec{x}_t) = \int p(\vec{x}_t \mid \vec{x}_{t-1}, \vec{u}_t) \cdot \text{bel}(\vec{x}_{t-1}) d\vec{x}_{t-1} \quad (4.10)$$

und bildet zusammen mit Gleichung (4.6) die folgende Berechnungsvorschrift des Bayes-Filter.

```

1 Algorithm: BayesFilter(bel( $\vec{x}_{t-1}$ ),  $\vec{u}_t$ ,  $\vec{z}_t$ ) :
2   for all  $\vec{x}_t$  do:
3      $\overline{\text{bel}}(\vec{x}_t) = \int p(\vec{x}_t \mid \vec{x}_{t-1}, \vec{u}_t) \cdot \text{bel}(\vec{x}_{t-1}) d\vec{x}_{t-1}$ 
4      $\text{bel}(\vec{x}_t) = \mu \cdot p(\vec{z}_t \mid \vec{x}_t) \cdot \overline{\text{bel}}(\vec{x}_t)$ 
5   endfor
6   return  $\text{bel}(\vec{x}_t)$ 

```

Listing 4.1: Bayes-Filter

Applikation, Interpretation und kritische Anmerkungen

Die bisherige Untersuchung hat sich auf die Herleitung der Berechnungsvorschrift und deren mathematischen Gültigkeit beschränkt, weshalb an dieser Stelle die Ergebnisse auf die konkrete Problemstellung der Lokalisierung übertragen werden. Dafür werden zunächst die Argumente des Algorithmus betrachtet: Bei den Vektoren \vec{u}_t und \vec{z}_t handelt es sich um die aktuellen Stell- und Messwerte. Der Erstgenannte enthält für gewöhnlich die aktuelle Geschwindigkeit des Roboters. In \vec{z}_t werden die aktuellen Sensorinformationen zusammengefasst, wobei es sich in diesem Fall um Distanzmessungen handelt, die mit einem Laserscanner gewonnen wurden. Das dritte Argument enthält die Wahrscheinlichkeit $bel(\vec{x}_{t-1})$ am vorherigen Abtastzeitpunkt, die für den Fall \vec{x}_0 initialisiert werden muss. Bei der Wahl der Startverteilung wird auf a priori Kenntnisse und Heuristiken zurückgegriffen. Beispielsweise kann der Anwender anhand einer Karte Positionen, die von einem Hindernis belegt sind, vorab ausschließen. Liegen keinerlei a priori Kenntnisse über die Ausgangsposition des Roboters vor, wird die Wahrscheinlichkeit $bel(\vec{x}_0)$ als Gleichverteilung initialisiert.

Als letzter Bestandteil des Filters müssen die bedingten Wahrscheinlichkeiten $p(\vec{x}_t | \vec{x}_{t-1}, \vec{u}_t)$ und $p(\vec{z}_t | \vec{x}_t)$ diskutiert werden. Die Verteilung $p(\vec{x}_t | \vec{x}_{t-1}, \vec{u}_t)$ gibt an, wie wahrscheinlich eine Position \vec{x}_t ausgehend von der Position \vec{x}_{t-1} mit dem Stellvektor \vec{u}_t erreicht werden kann. Es liegt also ein stochastisches Bewegungsmodell vor. Im Gegensatz zu seinem deterministischen Pendant wird anhand der Position \vec{x}_{t-1} und Geschwindigkeit \vec{x}_t keine exakte Position \vec{x}_t berechnet, sondern eine probabilistische Aussage darüber getroffen, mit welcher Wahrscheinlichkeit die gegebene Position \vec{x}_t erreicht werden wird.

Eine ähnlich Rolle übernimmt die Wahrscheinlichkeit $p(\vec{z}_t | \vec{x}_t)$, die ein Messmodell darstellt. Eine deterministische Analogie besteht in der Ausgangsgleichung eines Zustandsraummodells

$$\vec{y} = C(\vec{x}), \quad (4.11)$$

bei der anhand des Zustandsvektors \vec{x} ein Ausgangsvektor \vec{y} berechnet wird, der sich in der Regelungstechnik für gewöhnlich aus den gemessenen Größen zusammensetzt. Ähnlich wie bei dem Bewegungsmodell soll bei einem stochastischem Messmodell keine exakte Berechnung des Messvektors \vec{z}_t durchgeführt werden - insbesondere weil dieser bereits vorliegt. Die Aufgabe besteht vielmehr darin, zu schätzen wie wahrscheinlich ein gemessener Vektor \vec{z}_t aus einem gegebenen Zustand \vec{x}_t hervorgeht. Beispielsweise lässt sich mit recht hoher Wahrscheinlichkeit schließen, dass der Roboter unmittelbar vor einem Hindernis steht, wenn alle Abstandsmessungen sehr kleine Werte liefern.

Aus der Sicht des Applikators stellen die Verteilungen $p(\vec{x}_t | \vec{x}_{t-1}, \vec{u}_t)$ und $p(\vec{z}_t | \vec{x}_t)$ nicht nur Modelle sondern die relevanten Stellschrauben dar, um die Ergebnisse und Qualität des Filteralgorithmus zu beeinflussen. Folglich besteht die Hauptaufgabe darin, das stochastische Bewegungs- und Messmodell an die gegebenen Rahmenbedingungen anzupassen. Hier stellt sich die Frage, welche Form die Qualität eines stochastischen Modells annimmt. Aus der deterministischen Modellbildung ging bereits die Erkenntnis hervor, dass sich qualitativ hochwertige Modelle nicht durch einen unendlichen Detaillierungsgrad und der damit einhergehenden Genauigkeit auszeichnen. Das Gegenteil ist der Fall: Die hohe Kunst der Modellbildung besteht darin einen Kompromiss zwischen Detail und Aussagekraft zu finden.

Detailgetreue Modellierungstiefe bringt als unvermeidlichen Nachteil Komplexität mit sich; eine Komplexität, welche die Handhabung des Modells ungemein erschwert und die Nutzung des Modells behindert. Diese Aspekte motivieren die Philosophie einer Modellierungsform, die sich auf die markanten Charakteristika eines Prozesses beschränkt. Die für die Aufgabenstellung relevanten Eigenschaften geben die erforderliche Detailierungstiefe des Modells vor.

In diesem Sinne stellt das stochastische Modell aus mehreren Gründen eine mächtigen Ansatz dar. Während bei deterministischen Modellen die Vereinfachungen und Vernachlässigungen lediglich in Form von Annahmen in der begleitenden Dokumentation artikuliert werden können, bietet ein probabilistisches Modell die Möglichkeit Ungenauigkeiten als Wahrscheinlichkeit auszudrücken. Ebenso können heuristische Argumente, die sich nur schwer in einem deterministischen Kontext formulieren lassen, mithilfe einer probabilistischen Abschätzung in das mathematische Modell aufgenommen werden. Dieses Argument kommt besonders dann zum Tragen, wenn eine Problemstellung betrachtet wird, für die keinerlei physikalischen Gesetze bestehen. Beispielsweise steht im Fall des Bewegungsmodells das elaborierte Feld der technischen Mechanik bereit, um exakte Bewegungsgleichungen der Roboterdynamik zu formulieren. Lediglich deren unhandliche Komplexität motiviert die Verwendung simpler stochastischer Modelle. Eine andere Situation ergibt sich im Falle des Messmodells: Angenommen es werden Stereokameras verwendet, um die Distanz der umgebenden Hindernisse zu ermitteln. Es ist praktisch unmöglich einen exakten Zusammenhang zwischen der Umgebung, dem Messprinzip der Stereokameras und dem resultierenden Messvektor herzustellen. Somit bleibt dem Anwender keine andere Wahl als das Modell anhand von Heuristiken zu konstruieren, die wiederum auf stark vereinfachten Modellen und Annahmen basieren.

Aus diesen Betrachtungen folgt bereits ein wichtiger Gesichtspunkt für die Beurteilung der Filtermethoden: Ein schlechtes Ergebnis kann unter Umständen nicht von dem Algorithmus sondern von den verwendeten Modellen verschuldet sein. Insofern muss Vorsicht bei der Auswertung und Beurteilung von Experimenten walten, um ein vorzeitiges Verwerfen potenter Ansätze zu vermeiden. Aus diesem Blickwinkel sollen nun auch die bei der Herleitung des Bayes-Filter getroffenen Annahmen betrachtet werden. Es kann recht leicht argumentiert werden, weshalb die Annahmen nicht zutreffen können.

Beispielsweise folgte aus der Vollständigkeit des Zustandes \vec{x}_t die Gleichung

$$p(\vec{z}_t \mid \vec{x}_t, \vec{z}_{1:t-1}, \vec{u}_{1:t}) = p(\vec{z}_t \mid \vec{x}_t) , \quad (4.12)$$

welche wiederum bedeutet, dass die Messung \vec{z}_{t-1} nicht von vergangenen Messungen abhängt. Diese Umstand trifft nicht mehr zu sobald das Messglied einer PT1-Dynamik unterliegt. **Das Vollständigkeitsargument kann auch so verstanden werden, dass z_t schon von z_{t-1} abhängen darf, diese Abhängigkeit aber bereits in x_t steckt**

Die zweite Annahme bestand darin, dass die Stellgröße \vec{u}_t zufällig gewählt wird, und somit nicht von der Position \vec{x}_t abhängt. Diese Annahme ist vollkommen haltlos, da die Lokalisierung im Rahmen dieser Arbeit nur verfolgt wird, um das Ergebnis \vec{x}_t zur Berechnung einer Stellgröße \vec{u}_t zu verwenden. Zur Verteidigung des Verfahrens wird die Ungenauigkeit der Modelle aufgeführt, wobei argumentiert wird, dass die Modellfehler den Widerstoß gegen die bestehenden Annahmen überwiegen. Allerdings ist kritisch zu vermerken, dass es sich bei die-

sem Argument auch lediglich um eine Annahme handelt. An dieser Stelle offenbart sich eine Schwachstelle der stochastischen Ansätze: Es ist kaum möglich eine analytische Beurteilung der Verfahren durchzuführen. Der Vorteil, dass heuristische Argumente in Form von Wahrscheinlichkeiten ausgedrückt werden, verhindert gleichermaßen ein deterministisches, also ein absolutes Urteil. Als entscheidendes Kriterium bleibt lediglich das Experiment, wobei es wieder schwer fällt zwischen den Einflüssen des Algorithmus und der probabilistischen Modelle zu differenzieren.

4.2 Diskretes Bayes-Filter und Histogramm-Filter

Das bisher betrachtete Filter kann lediglich für kontinuierlich verteilte Wahrscheinlichkeiten verwendet werden, weshalb es nicht rechnerfähig und somit von geringem praktischem Nutzen ist. Für den Fall einer diskret verteilten Zufallsvariable lässt sich ein diskretes Bayes-Filter recht leicht konstruieren, indem das Integral des kontinuierlichen Filter durch eine finite Summe ersetzt wird.

```

1 Algorithm: DiscBayesFilter(bel( $\vec{x}_{t-1}$ ),  $\vec{u}_t$ ,  $\vec{z}_t$ ) :
2   for all  $\vec{x}_t$  do:
3      $\overline{\text{bel}}(\vec{x}_t) = \sum p(\vec{x}_t \mid \vec{x}_{t-1}, \vec{u}_t) \cdot \text{bel}(\vec{x}_{t-1})$ 
4      $\text{bel}(\vec{x}_t) = \mu \cdot p(\vec{z}_t \mid \vec{x}_t) \cdot \overline{\text{bel}}(\vec{x}_t)$ 
5   endfor
6   return bel( $\vec{x}_t$ )

```

Listing 4.2: Diskretes Bayes-Filter

Als Beispiel kann ein Schätzer dienen, der den Zustand einer Tür ermitteln soll. Diese kann entweder offen oder geschlossen sein, weshalb sich der Zustandsraum auf zwei mögliche Werte beschränkt.

In dem Fall, dass eine wertkontinuierliche Verteilung vorliegt, muss der Zustandsraum diskretisiert werden, um das diskrete Bayes-Filter applizieren zu können. Jedem Element \vec{x}_t , das in in der selben Region X_k des Zustandsraums liegt, wird dieselbe Wahrscheinlichkeit zugeordnet. Die diskretisierte Verteilung kann wiederum mit dem diskreten Bayes-Filter geschätzt werden, wobei in diesem Kontext von einem Histogramm-Filter gesprochen wird, um zu verdeutlichen, dass der diskreten Wahrscheinlichkeit ein wertkontinuierlicher Zustandsraum zu Grunde liegt.

In dieser Form kann das Histogramm-Filter genutzt werden, um das Lokalisierungsproblem zu lösen. Der Ansatz wird als Grid-Localization bezeichnet, da der Raum in ein Gitterraster unterteilt wird. Das Filter ordnet jeder Zelle eine Wahrscheinlichkeit zu, mit der sich der Roboter in der Zelle befindet.

4.3 Partikel-Filter

Die Eigenschaft des Histogramm-Filters, den Zustandsraum in gleichgroße Zellen zu unterteilen, entpuppt sich bei der Lokalisierung als Nachteil. In den meisten Anwendungsfällen kann ein Großteil des Zustandsraumes recht rasch ausgeschlossen werden, was sich in Form von verschwindend geringen Wahrscheinlichkeiten manifestiert. Es entsteht der Konflikt, dass einerseits eine möglichst grobe Diskretisierung gewählt werden möchte, um keine Ressourcen für irrelevante Gebiete des Zustandsraumes zu verschwenden, andererseits wird durch ein feines Raster die Präzision der Lokalisierung gesteigert. Im den Fall, dass a priori über die Umgebung vorliegen, kann eine ungleichmäßige Diskretisierung des Zustandsraums vorgenommen werden. Allerdings kann weder die Annahme getroffen werden, dass derartige Information über die Verteilung bekannt sind, noch wird dadurch das zu Grunde liegend Problem gelöst. Das Histogramm-Filter ist nicht in der Lage, die Ressourcen, welche die Verteilung repräsentieren, an die aktuellen Wahrscheinlichkeitswerte anzupassen.

Eine Lösung für dieses Problem liefert das Partikel-Filter, das die Verteilung durch eine finite Menge von Stichproben repräsentiert. Die Proben der Verteilung werden als Partikel bezeichnet, woher auch der Name des Filters stammt. Da die Partikel aus der Verteilung gezogen werden, folgt im Umkehrschluss, dass eine von vielen Partikeln bevölkerte Region mit einer hohen Wahrscheinlichkeit korrespondiert.

Listing 4.3: Partikel-Filter

```

1 ParticleFilter( $\mathcal{X}_{t-1}$ ,  $\bar{\mathbf{u}}_t$ ,  $\bar{\mathbf{z}}_t$ )
2    $\bar{\mathcal{X}}_t = \mathcal{X}_t = \emptyset$ 
3   for  $m = 1$  to  $M$  do
4     sample  $\bar{\mathbf{x}}_t^{[m]} \leftarrow p(\bar{\mathbf{u}}_t \mid \bar{\mathbf{x}}_t, \bar{\mathbf{x}}_{t-1}^{[m]})$ 
5      $\omega_t^{[m]} = p(\bar{\mathbf{z}}_t \mid \bar{\mathbf{x}}_t^{[m]})$ 
6     add  $(\bar{\mathbf{x}}_t^{[m]}, \omega_t^{[m]})$  to  $\bar{\mathcal{X}}_t$ 
7   endfor
8   for  $m = 1$  to  $M$  do
9     draw  $i$  with probability  $\omega_t^{[i]}$  //sollte das nicht folgende Zeile sein
10    draw  $i$  with probability  $\omega_t^{[m]}$ 
11    add  $\bar{\mathbf{x}}_t^{[i]}$  to  $\mathcal{X}_t$ 
12  endfor
13  return  $\mathcal{X}_t$ 

```

Listing 4.3: Partikel-Filter

Im ersten Schritt wird der Algorithmus heuristisch erläutert, um ein anschauliches aber dafür oberflächliches Verständnis für dessen Funktionsprinzip zu erhalten. Das Filter arbeitet rekursiv, so wird ihm die Partikelmenge des vorherigen Abtastzeitpunktes \mathcal{X}_{t-1} , sowie der Stellvektor $\bar{\mathbf{u}}_t$ und Messvektor $\bar{\mathbf{z}}_t$ übergeben. Im ersten Schritt wird die vorläufige Partikelmenge $\bar{\mathcal{X}}_t$ bestimmt, indem aus der Wahrscheinlichkeit $p(\bar{\mathbf{x}}_t \mid \bar{\mathbf{u}}_t, \bar{\mathbf{x}}_{t-1}^{[m]})$ und den vorherigen Partikeln $\bar{\mathbf{x}}_{t-1}^{[m]}$ neue Werte $\bar{\mathbf{x}}_t^{[m]}$ gezogen werden. Mit der Verteilung liegt ein Bewegungsmodell vor, weshalb die Stichprobe $\bar{\mathbf{x}}_t^{[m]}$ als der am wahrscheinlichsten auf den alten Zustand $\bar{\mathbf{x}}_{t-1}^{[m]}$ und Stellgröße $\bar{\mathbf{u}}_t$ folgende Zustand interpretiert werden kann. Im nächsten Schritt wird bestimmt, wie wahrscheinlich der Messvektor $\bar{\mathbf{z}}_t$ unter diesem neuen Partikeln $\bar{\mathbf{x}}_t^{[m]}$ auftritt. Diese Wahrscheinlichkeit $\omega_t^{[m]}$ wird auch als Gewichtung bezeichnet. Das so bestimmte Paar $(\bar{\mathbf{x}}_t^{[m]}, \omega_t^{[m]})$ wird der Menge $\bar{\mathcal{X}}_t$ hinzugefügt.

Der bisherige Schritt bestand lediglich darin, die Partikel des vorherigen Abtastpunktes der zeitlichen Veränderung anzupassen, woraus die vorläufige Menge $\overline{\mathcal{X}}_t$ resultiert ist. Im Anschluss werden die Partikel mit einer zu der Gewichtung $\omega_t^{[m]}$ proportionalen Wahrscheinlichkeit neu gezogen. Dieser Schritt wird dadurch motiviert, dass es sich bei $\omega_t^{[m]}$ um die Wahrscheinlichkeit handelt, dass der Messvektor aus dem Partikel $\vec{\mathbf{x}}_t^{[m]}$ resultiert. Insofern plausibilisiert $\omega_t^{[m]}$ sein zugehöriges Partikel $\vec{\mathbf{x}}_t^{[m]}$. Angenommen das Bewegungsmodell $p(\vec{\mathbf{u}}_t | \vec{\mathbf{x}}_t, \vec{\mathbf{x}}_{t-1}^{[m]})$ bringt ein Partikel \mathcal{X}_t hervor, das der Position des Roboters in einer Ecke entspricht. Befindet sich der Roboter in der Realität aber vor einer gerade verlaufenden Wand, so ergibt das Messmodell $p(\vec{\mathbf{z}}_t | \vec{\mathbf{x}}_t^{[m]})$ für das Partikel $\vec{\mathbf{x}}_t^{[m]}$ eine sehr geringe Gewichtung $\omega_t^{[m]}$. Weshalb das Partikel mit einer nur sehr geringen Wahrscheinlichkeit in die neue Menge \mathcal{X}_t übernommen werden. Genau durch diesen Mechanismus kompensiert das Partikel-Filter die Nachteile des Histogramm-Filters. Die Plausibilisierung mittels $\omega_t^{[m]}$ verhindert, dass unwahrscheinliche Hypothesen in Form von Partikeln verfolgt werden. Langfristig fokussieren sich die Partikel und somit auch die Ressourcen des Algorithmus auf die wahrscheinlichsten Hypothesen.

Schlechte Erklärung/Formulierung

Kapitel 5

ROS-Implementierung

Um die bisher gesammelten Kenntnisse über Planungs- und Navigationsalgorithmen auf den realen Anwendungsfall zu übertragen, muss der Umsetzung in ROS näher untersucht werden. Dieser Aufgabe widmet sich dieses Kapitel. Als eine Schwierigkeit zeigt sich, dass die vollständige Trennung und Entkopplung der funktionalen Aspekte und Implementierung nicht immer möglich ist.

5.1 Überblick und Gesamtkonzept

Der ROS-Navigation-Stack wird in dem Paket **move_base** implementiert. Das funktionale Herzstück bilden der lokale und globale Planer, die bereits in den vorherigen Abschnitten erläutert wurden. Für die Berechnung der Pfade werden simultan eine globale und lokale Kostenkarte verwaltet. An dieser Stelle liegt der Fokus auf der Umsetzung der Algorithmen im **move_base** Paket. Für den globalen als auch lokalen Planer werden zwei Kostenkarten verwaltet, die

color Wie viel Relevantes gibt es hier zu sagen? Und wo sollte das gesagt werden, wenn dann ganz am Anfang, vor jeder Erklärung zu Algorithmen

5.2 Globaler Planer

Für die Umsetzung der globalen Planung wird das ROS-Paket **global_planner** [6] verwendet. Die Funktion der Aktionsgewichtung $f(\vec{x}_t, \vec{u}_t)$ wird von einer Kostenkarte erfüllt, wobei es sich um ein Occupancy-Grid handelt, also einer ortsdiskreten Gitterdarstellung. Die Kostenkarte ordnet jeder Zelle einen Aufwand zu, der aufgebracht werden muss, um die Zelle zu passieren. In dem ROS-Paket kann konfiguriert werden, ob zur Lösung des diskreten Planungsproblems Dijkstras Algorithmus oder A^* verwendet werden soll.

Insgesamt können bei dem Planer sieben Parameter konfiguriert werden [?], wobei lediglich die folgenden für den Anwendungsfall von Interesse sind:

allow_unknown (bool, default: true)

Mit dem Parameter wird bestimmt, ob auch Pfade durch Zellen geplant werden soll, bei deren Zustand nicht bekannt ist.

default_tolerance (double, default: 0.0)

Toleranzabstand mit dem der geplante Pfad die Zielposition erreichen soll. Da bei der Planung eine diskrete Darstellung verwendet wird, entsteht durch die Default-Toleranz von 0 kein Problem.

use_dijkstra (bool, default:true)

Flag ob Dijkstra oder A^* verwendet werden soll. Der Grund für die Standardeinstellung ist, dass A^* nach [6] auf suboptimale Ergebnisse führen kann. Eine mögliche Erklärung für dieses Verhalten besteht darin, dass es sich bei der Heuristik für die Kostenrechnung um keine Unterschätzung des wirklichen Aufwandes handelt.

use_quadratic (bool, default:true)

Bei diesem Parameter kommt der Internetcharakter der ROS-Dokumentation das erste Mal zum Tragen. Nach [6] führt das Flag dazu, dass eine quadratische Approximation des Potentials - synonym für die Kosten - genutzt wird. Im Folgesatz schreiben die Autoren dennoch: "Of what, the maintainer of this package has no idea"[6]. Nach weiterer Internetquelle .. **Wie der Parameter genau funktioniert ist hier nicht wirklich relevant, eigentlich sollte man erst darauf eingehen, wenn das wichtig wird**

use_grid_path (bool, default:false)

Wenn auf **true** gestellt, folgt der Pfad wie in den obigen Beispielen den Zellen, was dazu führt, dass der Roboter sich nur in acht Richtungen bewegen kann - durch **use_quadratic** wird die schräge Bewegung ermöglicht. Der Standardwert des Parameters führt zu einer Glättung des Pfades, woraus rundere Bahnen resultieren.

5.3 Kostenkarten

Die Basis für die Berechnung des globalen Pfades stellt die globale Kostenkarte dar, die mithilfe des ROS-Pakets **costmap_2d** [8] erstellt wird. Wie der Name bereits erahnen lässt, wird das Paket genutzt, um 2D-Kostenkarten zu berechnen.

5.4 Lokaler Planer

Literaturverzeichnis

- [1] Sebastian, Thrun; Wolfram, Burgard; Dieter Fox: „Probabilistic Robotics“, 1. Auflage, Massachusetts Institute of Technology 2006, MIT Press
- [2] LaValle, Steven M. „Planning Algorithms“, 1. Auflage, Cambridge 2006, Cambridge University Press
- [3] Pearl, J. „Heuristics“, Addison-Wesley, 1984
- [4] Fikes, R. E.; Nilsson, N. J. „STRIPS: A new approach to the application of theorem proving.“Artificial Intelligence Journal, 1971
- [5] Clearpath Robotics „TurtleBot Data Sheet “2015
- [6] global_planner: http://wiki.ros.org/global_planner , aufgerufen am 30.11.2017
- [7] navfn algorism[sic]: <https://answers.ros.org/question/11388/navfn-algorism/?answer=16891#answer-container-16891>, aufgerufen am 30.11.2017
- [8] costmap_2d: http://wiki.ros.org/costmap_2d, aufgerufen am 30.11.2017
- [9] staticmap: http://wiki.ros.org/costmap_2d/hydro/staticmap, aufgerufen am 30.11.2017
- [10] obstacles: http://wiki.ros.org/costmap_2d/hydro/obstacles, aufgerufen am 30.11.2017
- [11] inflation: http://wiki.ros.org/costmap_2d/hydro/inflation, aufgerufen am 30.11.2017
- [12] dwa_local_planner: http://wiki.ros.org/dwa_local_planner, aufgerufen am 30.11.2017